


自然语言处理绪论



为什么要学习自然语言处理





为什么要学习自然语言处理



目录

CONTENTS

- 1 自然语言处理的概念
- 2 自然语言处理的难点
- 3 自然语言处理任务体系
- 4 自然语言处理技术发展历史

目录

CONTENTS

1

自然语言处理的概念

2

自然语言处理的难点

3


自然语言处理任务体系

4

自然语言处理技术发展历史


什么是自然语言处理？

- 语言是**思维的载体**，是人类交流思想、表达情感最自然、最方便的工具
 - 人类历史上大部分知识是以语言文字形式记载和流传的
- 自然语言指的是人类语言，特指**文本符号**，而非语音信号
- 自然语言处理（Natural Language Processing, NLP）
 - 用计算机来理解和生成自然语言的各种理论和方法



自然语言处理属于认知智能任务

- **认知智能**是人类和动物的主要区别之一
 - 需要更强的**抽象**和**推理**能力



目录

CONTENTS

1

自然语言处理的概念

2

自然语言处理的难点

3

自然语言处理任务体系

4

自然语言处理技术发展历史

自然语言处理的难点与特点

领导：“你这是什么意思？”

阿呆：“没什么意思，意思意思。”

领导：“你这就不够意思了。”


阿呆：“小意思，小意思。”

领导：“你这人真有意思。”

阿呆：“其实也没有别的意思。”

领导：“那我就不好意思了。”

阿呆：“是我不好意思。”



“人工智能皇冠上的明珠”

- 自然语言处理成为**制约人工智能取得更大突破和更广泛应用的瓶颈**



Yann LeCun
图灵奖得主、Facebook AI 负责人

“深度学习的下一个前沿课题是**自然语言理解**”




Geoffrey Hinton
图灵奖得主、深度学习之父

“深度学习的下一个大的进展应该是**让神经网络真正理解文档的内容**”





Michael I. Jordan
美国双院院士、世界知名机器学习专家

“如果给我10亿美金，我会用这10亿美金建造一个NASA级别的**自然语言处理**研究项目”



沈向洋
美国工程院院士、微软前全球执行副总裁

“下一个十年，**懂语言者**得天下”



图灵测试

目录

CONTENTS

1

自然语言处理的概念

2

自然语言处理的难点

3

自然语言处理任务体系


4

自然语言处理技术发展历史


自然语言处理任务层级



归结为四个基本问题



自然语言处理研究对象与层次



“层次 x 任务”二维表

	分类	解析	匹配	生成
形式	文本分类	词性标注 句法分析	搜索	机械式文摘
语义	情感分析	命名实体识别 语义角色标注	问答	机器翻译
推理	隐式情感分析		文本蕴含	写故事结尾
语境	反语			聊天

语言模型

- 语言模型 (Language Model, LM)

- 描述一段自然语言的概率或给定上文时下一个词出现的概率

- $P(w_1, \dots w_l), P(w_{l+1}|w_1, \dots w_l)$

- 以上两种定义等价 (链式法则)

$$P(w_1 w_2 \dots w_l) = P(w_1)P(w_2|w_1)P(w_3|w_1 w_2) \dots P(w_l|w_1 w_2 \dots w_{l-1}) = \prod_{i=1}^l P(w_i|w_{1:i-1})$$

- 广泛应用于多种自然语言处理任务

- 机器翻译 (词排序)

- $P(\text{the cat is small}) > P(\text{small the is cat})$

- 语音识别 (词选择)

- $P(\text{there are four cats}) > P(\text{there are for cats})$

中文分词

- 词 (Word)
 - 最小的能**独立使用**的音义结合体
 - 以汉语为代表的**汉藏语系**，以阿拉伯语为代表的**闪-含语系**中不包含明显的词之间的分隔符
- 中文分词是将中文字序列切分成一个个单独的词
- 分词的歧义
 - 如：**严守一把手机关了**
 - 严守一/ 把/ 手机/ 关/ 了
 - 严守/ 一把手/ 机关/ 了
 - 严守/ 一把/ 手机/ 关/ 了
 - 严守一/ 把手/ 机关/ 了
 -

子词切分 (Subword)

- 以**英语**为代表的印欧语系语言，是否需要进行分词？
- 这些语言**词形变化**复杂
 - 如：computer、computers、computing等
- 仅用**空格**切分的问题
 - 数据稀疏
 - 词表过大，降低处理速度
- 子词切分
 - 将一个单词切分为若干连续的**片段**（子词）
 - 方法众多，**基本原理相似**
 - 使用尽量长且频次高的子词对单词进行切分

句法分析


- 分析句子的**句法成分**，如主谓宾定状补等
- 将词序列表示的句子转换成**树状结构**

山寨发布会阳淼

@才看到。昨天手机打字，把“您转的这篇文章很无知”打成了“您转这篇文章很无知”，少了一个的字。抱歉。

山寨发布会阳淼

主语是那篇文章很无知。




<http://ltp.ai/demo.html>

语义分析

- 词义消歧 (Word Sense Disambiguation, WSD)
- 语义角色标注 (Semantic Role Labeling, SRL)
 - 也称谓词论元结构 (Predicate-Argument Structure)

输入	他	喜欢	下	象棋	。
输出 1	施事	谓词		受事	
输出 2	施事		谓词	受事	

- 语义依存图 (Semantic Dependency Graph)



信息抽取

- 信息抽取（Information Extraction, IE）
 - 从非结构化的文本中自动提取结构化信息

输入

10月28日，AMD宣布斥资350亿美元收购FPGA芯片巨头赛灵思。这两家传了多年绯闻的芯片公司终于走到了一起。

信息抽取子任务	抽取结果
命名实体识别	公司名：AMD 公司名：赛灵思
关系抽取	赛灵思 $\xrightarrow{\text{从属}}$ AMD
时间表达式抽取	10月28日
时间表达式归一化	10月28日 $\rightarrow$ 2020年10月28日
事件抽取	事件：收购 时间：2020年10月28日 收购者：AMD 被收购者：赛灵思 收购金额：350亿美元

情感分析

- 情感分析 (Sentiment Analysis)
 - 个体对外界事物的**态度**、**观点**或**倾向性**，如正面、负面等
 - 人自身的**情绪** (Emotion)，如喜怒哀惧等
- 输入
 - *这款手机的屏幕很不错，性能也还可以。*

情感分析子任务	分析结果
情感分类	褒义
情感信息抽取	评价词：不错；可以 评价对象：屏幕；性能 评价搭配：屏幕 ⇔ 不错；性能 ⇔ 可以

问答系统

- 问答系统（Question Answering, QA）
 - 用户以**自然语言形式描述问题**，从异构数据中获得答案
- 根据数据来源的不同，问答系统可以分为4种主要的类型
 - **检索式**问答系统
 - 答案来源于固定的文本语料库或互联网，系统通过查找相关文档并抽取答案完成问答
 - **知识库**问答系统
 - 回答问题所需的知识以数据库等结构化形式存储，问答系统首先将问题解析为结构化的查询语句，通过查询相关知识点，并结合知识推理获取答案
 - **常问问题集**问答系统
 - 通过对历史积累的常问问题集合进行检索，回答用户提出的类似问题
 - **阅读理解式**问答系统
 - 通过抽取给定文档中的文本片段或生成一段答案来回答用户提出的问题

更多任务

- 机器翻译 (Machine Translation, MT)
- 对话系统 (Dialogue System)

	任务型 Task	聊天 Chat	知识问答 Knowledge	推荐 Recommen- dation
目的	完成任务或动作	闲聊	知识获取	信息推荐
领域	特定域 (垂类)	开放域	开放域	特定域
以话轮数评价	越少越好	话轮越多越好	越少越好	越少越好
应用	虚拟个人助理	娱乐、情感陪护	客服、教育	个性化推荐
典型系统	Siri、Cortana、Google Assistant、度秘	小冰、笨笨	Watson、Wolfram Alpha	阿里小蜜

目录

CONTENTS

1

自然语言处理的概念

2

自然语言处理的难点

3


自然语言处理任务体系

4


自然语言处理技术发展历史

自然语言处理技术发展历史

- 语义在计算机内部是如何**表示**的？
- 根据表示方法的不同，自然语言处理技术经历了**五（四）次范式变迁**



基于符号（字符串）表示的专家知识



- “土豆非常好吃。”的情感倾向性？

- 如果：出现褒义词“好”“喜欢”等
- 那么：结果为褒义
- 如果：出现“不”
- 那么：结果倾向性取反



□ 优点

- 符合人类的直觉
- 可解释、可干预性好

□ 缺点


- 知识完备性不足
- 需要专家构建和维护
- 不便于计算

基于向量表示的统计模型




- 使用**高维、离散、稀疏**的向量表示词
 - 维度为词表大小，其中只有一位为1，其余为0
 - **土豆** : $[0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, \dots]$
 - **马铃薯** : $[0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, \dots]$
- 缺点
 - 无法处理“**多词一义**”的现象

基于嵌入表示的深度学习模型




- 词嵌入 (Word Embedding)
 - 直接使用一个**低维、连续、稠密**的向量表示词 (Bengio等2003)




词嵌入表示的赋值方法

- 通过优化在**下游任务**上的表现自动学习



预训练模型获得更好的表示



预训练 + 精调 = 自然语言处理的经典范式

大模型


小规模专家知识
1950~1990

深度学习模型
2010~2017


ChatGPT
2023~?

浅层机器学习算法
1990~2010

预训练语言模型
2018~2023



模型	发布时间	大小 (B)	基础模型	IT	RLHF	预训练数据规模	最新数据的发布时间	硬件 (GPUs / TPUs)	训练时间	评估 ICL CoT
T5	2019年10月	11	-	-	-	1 万亿 tokens	2019年04月	1024 TPU v3	-	✓
mT5	2020年10月	13	-	-	-	1 万亿 tokens	-	-	-	✓
PanGu-α	2021年04月	13*	-	-	-	1.1TB	-	2048 Ascend 910	-	✓
CPM-2	2021年06月	108	-	-	-	2.6TB	-	-	-	✓
T0	2021年10月	11	T5	✓	-	-	-	512 TPU v3	27 小时	✓
CodeGen	2022年03月	16	-	-	-	5770 亿 tokens	-	96 40G A100	-	✓
GPT-NeoX-20B	2022年04月	20	-	-	-	825GB	-	256 TPU v3	4 小时	✓
Tk-Instruct	2022年04月	11	T5	✓	-	-	-	512 TPU v4	-	✓
UL2	2022年05月	20	-	-	-	1 万亿 tokens	2019年04月	992 80G A100	-	✓
OPT	2022年05月	175	-	-	-	1800 亿 tokens	-	768 40G A100	60 天	✓
NLLB	2022年07月	64.5	-	-	-	4000 亿 tokens	-	384 80G A100	105 天	✓
GLM	2022年10月	130	-	-	-	3660 亿 tokens	-	128 40G A100	-	✓
Flan-T5	2022年10月	11	T5	✓	-	-	-	2128 GPU	-	✓
BLOOM	2022年11月	176	-	-	-	1060 亿 tokens	-	-	-	✓
mT0	2022年11月	13	mT5	✓	-	-	-	-	-	✓
Galactica	2022年11月	120	-	-	-	-	-	-	-	✓
BLOOMZ	2022年11月	176	BLOOM	✓	-	-	-	-	-	✓
OPT-IML	2022年12月	175	OPT	✓	-	-	-	-	-	✓
LLaMA	2023年02月	65	-	-	-	1.4 万亿 tokens	-	2048 80G A100	21 天	✓
CodeGeex	2023年09月	13	-	-	-	8500 亿 tokens	-	1536 Ascend 910	60 天	✓
Pythia	2023年04月	12	-	-	-	3000 亿 tokens	-	256 40G A100	-	✓
GPT-3	2020年05月	175	-	-	-	3000 亿 tokens	-	-	-	✓
GShard	2020年06月	600	-	-	-	1 万亿 tokens	-	2048 TPU v3	4 天	✓
Codex	2021年07月	12	GPT-3	-	-	1000 亿 tokens	2020年05月	-	-	✓
ERNIE 3.0	2021年07月	10	-	-	-	3750 亿 tokens	-	384 V100	-	✓
Jurassic-1	2021年08月	178	-	-	-	3000 亿 tokens	-	800 GPU	-	✓
HyperCLOVA	2021年09月	82	-	-	-	3000 亿 tokens	-	1024 A100	13.4 天	✓
FLAN	2021年09月	137	LaMDA-PT	✓	-	-	-	128 TPU v3	60 小时	✓
Yuan 1.0	2021年10月	245	-	-	-	1800 亿 tokens	-	2128 GPU	-	✓
Anthropic	2021年12月	52	-	-	-	4000 亿 tokens	-	-	-	✓
WebGPT	2021年12月	175	GPT-3	✓	-	-	-	-	-	✓
Gopher	2021年12月	280	-	-	-	3000 亿 tokens	-	4096 TPU v3	920 小时	✓
ERNIE 3.0 Titan	2021年12月	260	-	-	-	-	-	-	-	✓
GLM	2021年12月	1200	-	-	-	2800 亿 tokens	-	1024 TPU v4	574 小时	✓
LaMDA	2022年01月	137	-	-	-	7680 亿 tokens	-	1024 TPU v3	57.7 天	✓
MT-NLG	2022年01月	530	-	-	-	2700 亿 tokens	-	4480 80G A100	-	✓
InstructGPT	2022年02月	41	-	-	-	9670 亿 tokens	2021年07月	-	-	✓
Chinchilla	2022年03月	70	GPT-3	✓	✓	-	-	-	-	✓
PaLM	2022年04月	70	-	-	-	1.4 万亿 tokens	-	6144 TPU v4	-	✓
AlcaM	2022年04月	20	-	-	-	7800 亿 tokens	-	128 A100	120 天	✓
Sparrow	2022年08月	70	-	-	-	1.3 万亿 tokens	-	64 TPU v3	-	✓
WdLM	2022年09月	10	-	-	-	3000 亿 tokens	-	128 A100 40G	24 天	✓
U-PaLM	2022年10月	540	PaLM	-	-	-	-	512 TPU v4	5 天	✓
Flan-PaLM	2022年10月	540	PaLM	✓	-	-	-	512 TPU v4	37 小时	✓
Flan-U-PaLM	2022年10月	540	U-PaLM	✓	-	-	-	-	-	✓
GPT-4	2023年03月	-	-	✓	✓	-	-	-	-	✓
PanGu-Σ	2023年03月	1085	PanGu-α	-	-	3290 亿 tokens	-	512 Ascend 910	100 天	✓





Wayne Xin Zhao et al, A Survey of Large Language Models.

大模型是王道？

参考书

- 《自然语言处理：基于预训练模型的方法》
 - 出版社：电子工业出版社
 - 作者：车万翔，郭江，崔一鸣 著；刘挺 主审
 - 书号：ISBN 978-7-121-41512-8
 - 出版时间：2021.7
- 网购链接
 - <https://item.jd.com/13344628.html>
- 书中代码
 - <https://github.com/HIT-SCIR/plm-nlp-code>





<https://web.stanford.edu/%7Ejurafsky/>



DAN JURAFSKY
Jackson Eli Reynolds Professor
in Humanities,
Professor of Linguistics
Stanford University

I study natural language processing and its application to the social and cognitive sciences. I am a past MacArthur Fellow and also work on the language of food.

jurafsky@stanford.edu
Margaret Jacks 117
Stanford CA 94305-2150

BIO

TWITTER: @jurafsky

CV

PEOPLE

NLP group

WHERE'S DAN?

LANGUAGE OF FOOD

class

articles

TEACHING

WINTER 2023

cs124/ling 180:

From Languages to Information

Tu/Th 3:05 PM - 4:20 PM

SPRING 2023

CS 384: Seminar on Social and Ethical

Issues in Natural Language Processing

Th 3:05-5:00 PM

CS 339R: Race and Natural Language

Processing (co-taught with Jennifer

Eberhardt)

Tue 3:30-4:00 PM

Earlier Courses

LECTURE VIDEOS

CS124: Youtube lecture videos

2012 NLP Online w/Chris Manning

- Youtube channel lecture videos

- Slides

BOOKS



2022 ARTICLES [ALL PUBS] [GOOGLE SCHOLAR]

Dallas Card, Serina Chang, Chris Becker, Julia Mendelsohn, Rob Voigt, Leah

Boustan, Ran Abramovsky, and Dan Jurafsky. 2022. Computational analysis

of 160 years of US political speeches reveals more positive but increasingly

polarized framing of immigration. Proceedings of the National Academy of

Sciences 119 (31):e2120510119. [pdf]

Sterling Alci, Dorothy Demery, Zofia Mancoff, Jing Liu, Heather Hill &

Dan Jurafsky. 2022. Computationally Identifying Framing and Focusing

Questions in Classroom Discourse: 17th Workshop on Innovative Use of

NLP for Building Educational Applications (IUEA) [pdf]

Katlyn Zhou, Kavin Eshayesh, Dallas Card, Dan Jurafsky. 2022. Problems

with Cosine as a Measure of Embedding Similarity for High-Frequency

Words. ACL 2022. [pdf]

Katlyn Zhou, Kavin Eshayesh, Dan Jurafsky. 2022. Richer Countries and

Richer Representations. ACL 2022. Findings. [pdf]

San, N., Banfield, M., Ögünç, T., Mount, A., Thompson, R., Higgins, M.,

Barker, R., Simpson, J., & Jurafsky, D. 2022. Automated speech tools for

helping communities process restricted-access corpora for language

revival efforts. In Proceedings of the 5th Workshop on the Use of

Computational Methods in the Study of Endangered Languages

(ComputEL) [pdf]

Junshan Chen, Dallas Card, and Dan Jurafsky. 2022. Modular Domain

Adaptation. ACL 2022. Findings. [pdf]

Stephan Risi, Crystal Lee, Mathias W. Kellen, Emma Kent, Ewan Brady, Lina

Kim, Daniel A. McFarland, Dan Jurafsky, James Zou, and Londa Schiebinger

2022. Diversifying History: A Large-Scale Analysis of Changes in Researcher

Demographics and Scholarly Agenda. PLoS One 17(1). [pdf]

Bradley P. Turnwald, Margaret A. Perry, David Jurgens, Vinod Kumar

Prabhakaran, Dan Jurafsky, Hazel R. Markus, Alla J. Crum. 2022. Language

in popular American culture constrains the meaning of healthy and

unhealthy eating: Narratives of craveability, excitement, and social


connection in movies, television, social media, recipes, and food reviews.

Appetite, Volume 172. [pdf]

NLP 入门推荐书目(2019 年 2 月)

自然语言处理	
信息检索导论 原作者: Introduction to Information Retrieval 作者: Christopher D Manning / Hinrich Schütze / Prabhakar Raghavan 出版社: 人民邮电出版社; 出版年: 2010 年; 页数: 388 必读: 第 2、6 章; 选读: 第 11、12、13、14、15、16、17、18、21 章	
统计自然语言处理 (第 2 版) 作者: 李航 出版社: 清华大学出版社; 出版年: 2013 年; 页数: 570	
Neural Network Methods for Natural Language Processing 作者: Yoshua Bengio 出版社: Synthesis Lectures on Human Language Technologies (Morgan & Claypool Publishers); 出版年: 2017; 页数: 310	
机器学习	
统计学习方法 作者: 李航 出版社: 清华大学出版社; 出版年: 2012 年; 页数: 235	
机器学习 作者: 周志华 出版社: 清华大学出版社; 出版年: 2016 年; 页数: 425	
Deep Learning 作者: Ian Goodfellow / Yoshua Bengio / Aaron Courville 出版社: MIT Press; 出版年: 2016 年; 页数: 800	
人工智能	
人工智能: 一种现代的方法 原作者: Artificial Intelligence: A Modern Approach 作者: [美国] 诺维格 / [美国] 罗素 出版社: 清华大学出版社; 出版年: 2013 年; 页数: 918	
社会计算	
网络、群体与市场: 揭示高度互联世界的行为原理与效应机制 原作者: Networks, Crowds, and Markets 作者: [美] 大卫·伊斯利 / [美] 乔恩·克莱因伯格 出版社: 清华大学出版社; 出版年: 2011 年; 页数: 511 必读: 第一部分、第四部分; 选读: 第五部分、第六部分	
推荐学术网站:	
1. Google Scholar: http://scholar.google.com/ 2. ACM Portal: http://dl.acm.org/ 3. ACL Anthology: http://www.aclweb.org/anthology/	

知乎 @刘知远



CS224N Home Coursework Schedule Office Hours Final projects Lecture Videos Ed Forum



CS224N: Natural Language Processing with Deep Learning

Stanford / Spring 2024



Natural language processing (NLP) is a crucial part of artificial intelligence (AI), modeling how people share information. In recent years, deep learning approaches have obtained very high performance on many NLP tasks. In this course, students gain a thorough introduction to cutting-edge neural networks for NLP.

Instructors

Teaching Assistants



Chris Manning



Aditya Agrawal



Anna Goldie



Archit Sharma



Arvind Mahankali



Chaofei Fan



Dan Jurafsky



James H. Martin



John Goldberger



Lina Kim



Emma Kent



Ewan Brady

<https://web.stanford.edu/class/cs224n/>

<https://github.com/intro-nlp/intro-nlp.github.io>

<https://intro-llm.github.io>

基础知识

- Proficiency in Python
 - All class assignments will be in Python (using NumPy and PyTorch)
- College Calculus, Linear Algebra
 - You should be comfortable taking (multivariable) derivatives and understanding matrix/vector notation and operations.
- Basic Probability and Statistics
 - You should know the basics of probabilities, gaussian distributions, mean, standard deviation, etc.
- Foundations of Machine Learning (e.g. CS221, CS229, CS230, or CS124)

一些重要资源

- 重要的学术会议

- 国内 中国计算机学会NLP&CC, 中国中文信息学会大模型会议、CCL, CCMT, CCIR等
- 国际 ACL, EMNLP, NAACL(<https://aclanthology.org>)、Coling、NeurIPS、ICML、ICLR

- 相关的学术方向

- 计算语言学、语言学等
- 机器学习、深度学习

- 相关的研究机构、研究组



一些重要资源

- 重要的学术组织



小结

CONTENTS

1

自然语言处理的概念

2

自然语言处理的难点

3

自然语言处理任务体系

4

自然语言处理技术发展历史

谢谢！