



静态词向量预训练模型

目录

CONTENTS

1

神经网络语言模型

2

Word2vec词向量

3

GloVe模型

4

静态词向量的评价与标准

目录

CONTENTS

1

神经网络语言模型

2

Word2vec词向量

3

GloVe模型

4

静态词向量的评价与标准

统计语言模型

□ 语言模型如何给文本分配概率

- 预测下一个出现的是什么词：给定一个文本 $x^{(1)}, \dots, x^{(T)}$ ，这个文本的概率是（根据语言模型）：

$$\begin{aligned} P(x^{(1)}, \dots, x^{(T)}) &= P(x^{(1)}) \times P(x^{(2)} | x^{(1)}) \times \dots \times P(x^{(T)} | x^{(T-1)}, \dots, x^{(1)}) \\ &= \prod_{t=1}^T P(x^{(t)} | x^{(t-1)}, \dots, x^{(1)}) \end{aligned}$$


给定单词序列 $x^{(1)}, x^{(2)}, \dots, x^{(t)}$ ，计算下一个单词 $x^{(t+1)}$ 的分布

$$P(x^{(t+1)} | x^{(t)}, \dots, x^{(1)})$$

$x^{(t+1)}$ 是词典 $V = \{w_1, \dots, w_{|V|}\}$ 中任意一个词。

向量空间模型（将词表示为离散符号）

- 问题：如何表示一个文档？
- 答案：向量空间模型(bag of words)
- 定义：
 - 向量空间模型是把一个文档表示为一个向量
 - 向量中的每一维来自于词典中的每个词
- 想法：收集文档中出现的所有词，并构建一个向量空间，空间的维数为词的数量，文档表示为这个向量空间中的一个向量。

将词表示为离散符号

苹果将于今年9月发售新款iphone14
烟台是中国苹果栽培最早的地方
华为手机隶属于华为消费者业务

苹果/将/于/今年/9/月/发售/新款/iphone14/
烟台/是/中国/苹果/栽培/最早/的/地方/
华为/手机/隶属于/华为/消费者/业务/

[“月”,“将”,“9”,“是”,“地方”,“今年”,“手机”,“消费者”,“栽培”,“于”,“业务”,“中国”,“新款”,“烟台”,
“最早”,“隶属于”,“ipone14”,“苹果”,“华为”,“发售”,“的”]

月	将	9	是	地方	今年	手机	消费者	栽培	于	业务	中国	新款	烟台	最早	隶属于	ipone14	苹果	华为	发售	的
0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
月	将	9	是	地方	今年	手机	消费者	栽培	于	业务	中国	新款	烟台	最早	隶属于	ipone14	苹果	华为	发售	的

将词表示为离散符号

苹果将于今年9月发售新款iphone14
烟台是中国苹果栽培最早的地方
华为手机隶属于华为消费者业务

苹果/将/于/今年/9/月/发售/新款/iphone14/
烟台/是/中国/苹果/栽培/最早/的/地方/
华为/手机/隶属于/华为/消费者/业务/

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
月	将	9	是	地方	今年	手机	消费者	栽培	于	业务	中国	新款	烟台	最早	隶属于	ipone14	苹果	华为	发售	的
1	1	1			1				1			1				1	1		1	
			1	1				1			1		1	1			1			1
						1	1			1					1			1	1	

	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
苹果	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0
手机	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0
ipone14	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0
华为	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0

独热向量
(one-hot)

将词表示为离散符号

苹果将于今年9月发售新款iphone14

烟台是中国苹果栽培最早的地方

华为手机隶属于华为消费者业务

苹果/将/于/今年/9/月/发售/新款/iphone14/

烟台/是/中国/苹果/栽培/最早/的/地方/

华为/手机/隶属于/华为/消费者/业务/

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
月	将	9	是	地方	今年	手机	消费者	栽培	于	业务	中国	新款	烟台	最早	隶属于	ipone14	苹果	华为	发售	的
1	1	1			1				1			1				1	1		1	
			1	1				1			1		1	1			1			1
						1	1			1					1			1	1	

- 例子：若要计算“苹果将于今年9月发售新款iphone14”、“烟台是中国苹果栽培最早的地方”和“华为手机隶属于华为消费者业务”三个句子之间的相似度。

分布式词表示


□ 分布表示的缺点

- 训练速度慢，增加新语料库困难
- 不易扩展到短语、句子表示

□ 分布式表示直接使用低维、稠密、连续的向量表示词

- 通过“自监督”的方法直接学习词向量
- 也称词嵌入 (Word Embedding)

□ 发展历程



预训练任务

- 给定一段文本 $w_1w_2 \cdots w_n$ ，语言模型的基本任务是根据历史上下文对下一时刻的词进行预测，也就是计算条件概率 $P(w_t|w_1w_2 \cdots w_{t-1})$
- 我们可以把语言模型转化以词表为类别标签集合的分类问题，输入为历史词序列 $w_1w_2 \cdots w_{t-1}$ （也记 $w_{1:t-1}$ ），输出为目标词 w_t 。
- 这样就可以从无标注的文本语料库中构建训练数据集，通过优化该数据集上的分类损失对模型进行训练。
- 由于这种方式中的监督信号来自数据本身，因此这种学习方式也称为**自监督学习（Self-supervised learning）**。

前馈神经网络语言模型（FF-NNLM）

□ Neural Network Language Models (Bengio et al., JMLR 2003)

□ 根据前 $n-1$ 个词（历史）预测当前词，即马尔可夫假设：

$$\square P(w_t|w_{1:t-1})=P(w_t|w_{t-n+1:t-1})$$

□ 模型结构为前馈神经网络

□ 通过查找表（Look-up Table），获得词的向量表示

□ 词向量（或词嵌入，Word Embedding）


□ 支撑Bengio图灵奖的重要工作

□ 模型的任务是对条件概率 $P(w_t|w_{t-n+1:t-1})$ 进行估计

□ 通过梯度下降优化词向量表示

□ 缺点


□ 历史“长度不可变”



前馈神经网络语言模型 (FF-NNLM)

Neural Network Language Models (Bengio et al., JMLR 2003)


前馈神经网络由输入层、词向量层、隐含层和输出层构成



前馈神经网络语言模型 (FF-NNLM)

□ Neural Network Language Models (Bengio et al., JMLR 2003)

□ 前馈神经网络由输入层、词向量层、隐含层和输出层构成



循环神经网络语言模型（RNNLM）

❑ Recurrent Neural Network Language Models (Mikolov et al., Interspeech, 2010)

❑ 根据完整的“历史”对当前词进行预测

❑ 对不定长依赖的建模能力

❑ 梯度弥散/爆炸问题


❑ 反向传播过程中按长度进行截断

❑ 长短时记忆网络（LSTM）

❑ 缺点

❑ “语言模型”约束

❑ ：只利用了“历史”信息



SENNA

□ Semantic/syntactic Extraction using a Neural Network Architecture

□ Natural Language Processing (Almost) from Scratch (Collobert et al., JMLR 2011)

□ “换词”的思想

□ 一个词和它的上下文构成正例

□ 随机替换掉该词构成负例


+ cat sits on a mat

— cat sits Harbin a mat

□ 优化目标

□ $\text{score}(\text{cat sits on a mat}) > \text{score}(\text{cat sits Harbin a mat})$

□ score的计算方式



□ 训练速度慢，在当年的硬件条件下需要训练1个月

目录

CONTENTS

1

神经网络语言模型

2

Word2vec词向量

3

GloVe模型

4

静态词向量的评价与标准


将词表示为离散符号

- 例子：使用搜索引擎搜索“Seattle motel”，我们也会希望搜索到一个包含“Seattle hotel”的模型。

motel = [0 0 0 0 0 0 0 0 0 0 0 ... 0 **1** 0 0 0]
hotel = [0 0 0 0 0 0 **1** 0 0 0 0 ... 0 0 0 0 0]

上述两个向量是正交的，无法度量相似度，且无法考虑词序

- 解决办法：
 - 通过同义词表来计算相似度 **难以量化!**
 - 替代办法：学习编码向量本身的相似性



2024年诺贝尔物理学奖颁发给了约翰·霍普菲尔德 (John Hopfield)与杰弗里·辛顿 (Geoffrey Hinton)，以表彰他们在人工神经网络机器学习方面的基础性发现和发明。



邱锡鹏

当神经网络成为人类生活的一部分，人工智能作为研究对象本身就变成了 science。可以预见：未来神经网络的机理研究会变成和脑科学一样重要，也是诺奖的涵盖领域。



刚刚！2024年诺贝尔物理学奖揭晓！

1分钟前



车万翔 (Wanxiang)

人工智能终于不是技术，而是科学啦 🤖



刚刚，2024年诺贝尔物理学奖揭晓

2分钟前



啊这...，我还在从事本科物理学的相关研究工作吗？[Onlooker][Onlooker][Onlooker]

感觉我现在做的一些工作是离诺贝尔最近的一次，哈哈

基于上下文的词的表示

- 分布式语义 (Distributional semantics) : A word's meaning is given by the words that frequently appear close-by

“A word is characterized by the company it keeps.”

-J.R.Firth, 1957



“One of the most successful ideas of modern statistical NLP!”

-Christopher Manning

- 什么是上下文 (Context) :
 - 当一个词 w 在文本中出现, 它的上下文就是出现在它附近的一组词 (在给定的窗口内)

基于上下文的词的表示

- 使用 w 的许多上下文就可以建立 w 的表示

...government debt problems turning into banking crises as happened in 2009...

...saying that Europe needs unified banking regulation to replace the hodgepodge...

.....India has just given its banking system a shot in the arm...

基于上下文的词的表示


- 使用 w 的许多上下文就可以建立 w 的表示

...government debt problems turning into banking crises as happened in 2009...

...saying that Europe needs unified banking regulation to replace the hodgepodge...

.....India has just given its banking system a shot in the arm...

这些上下文可以用来表示 banking



The diagram illustrates how context sentences are used to represent a word. At the top, three sentences are listed, each with the word 'banking' highlighted in pink. Below these sentences, the Chinese text '这些上下文可以用来表示 banking' (These contexts can be used to represent banking) is shown. Two arrows point from this text to the 'banking' words in the first and third sentences, indicating that the surrounding context is used to derive a representation for the word.

词向量

- 我们可以为每一个词 w 构建一个稠密向量
- 问题：选择什么样的词向量
 - w 与出现在上下文中的词更相似

$$\text{banking} = \begin{bmatrix} 0.286 \\ 0.792 \\ -0.177 \\ -0.107 \\ 0.109 \\ -0.542 \\ 0.349 \\ 0.271 \end{bmatrix}$$

- 注意：词向量也被称为词嵌入（word embeddings）或神经词表示(neural word representations)，它们都是一种分布式（distributed）表示。


神经语言模型

- 问题：怎么构建神经网络学习词嵌入
- 神经语言模型(A neural language model)

嵌入层 (Embedding Layer)：通过将索引向量与单词嵌入矩阵进行相乘，得到词嵌入

中间层 (Intermediate Layer(s))：产生输入的中间表示的一层或多层网络，例如一个全连接网络，应用于 w 的前 n 个词的词嵌入的拼接 (concatenation)上

Softmax 层 (Softmax Layer)：网络的最后一层，用于生成可能的词的概率分布



Bengio Y, Ducharme R, Vincent P, et al. A neural probabilistic language model. Journal of Machine Learning Research, 2003.

神经语言模型

- 神经语言模型需要学习以下表示：

$$f(\mathbf{w}_i, \cdots, \mathbf{w}_{i-n+1}) = P(\mathbf{w}_i | \mathbf{w}_{i-(n-1)}, \cdots, \mathbf{w}_{i-1})$$


- 遍历整个文档集，模型的目标函数为：

$$\sum_D P(\mathbf{w}_i | \mathbf{w}_{i-(n-1)}, \cdots, \mathbf{w}_{i-1})$$

- 一个映射 C 将 V 中的任何第 i 个词 w_i 映射到一个实值向量 $C(i) \in R^m$, $C(i)$ 表示与词汇表中每个单词相关联的分布式特征向量
- 一个函数 g 映射 w_i 的上下文中单词的特征向量的输入序列, $(C(w_{t-n-1}), \cdots, C(w_{t-1}))$ 到 w_i 的条件概率

神经语言模型

- 模型的目标函数为： $f(w_i, \dots, w_{i-n+1}) = P(w_i | w_{i-(n-1)}, \dots, w_{i-1})$



$$P(w_i | w_{i-(n-1)}, \dots, w_{i-1}) = \frac{\exp(y(w_i))}{\sum_{k=1}^{|V|} \exp(y(w_k))}$$

$$h = \tanh(b + Hx)$$

$$x = [C(w_{i-n+1}); \dots; C(w_{i-1}); C(w_{i-1})]$$

$$\tanh = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

将 $w_{i-n+1}, \dots, w_{i-1}$ 中的每个词向量按顺序拼接

- 问题：怎么计算 $C(w_{t-n-1}), \dots, C(w_{t-1})$

- 方法：**梯度下降** (Gradient Descend)

$$\theta = \theta + \alpha \frac{\partial \log P(w_i | w_{i-(n-1)}, \dots, w_{i-1})}{\partial \theta}$$

C&W模型

- 这是一个NLP的深层神经网络架构

- 学习目标是：

$$\sum_{s \in \mathcal{S}} \sum_{w \in \mathcal{D}} \max(0, 1 - f(s, w_s^*) + f(s, w))$$

$\mathcal{S}$: sentence windows $\mathcal{D}$: dictionary


w_s^* : true middle word in s

$f(s, w)$: network score for sentence s and middle word w

- 优势：


- 对NLP标记任务通用
- 联合训练

Collobert R, Weston J. A unified architecture for natural language processing: deep neural networks with multitask learning. International conference on machine learning, 2008



Word2vec概述

- Word2vec：是Google提出的一个学习词嵌入的框架
- 想法：
 - 我们有一个非常大规模的文档集
 - 有一个固定的词典，其中的每个词被表示为一个**向量**
 - 浏览文本中的每个位置 t ，其中有一个中心词 c 和上下文（“外部”）词 o
 - 使用 c 和 o 的**词向量的相似度**来**计算**给定 c 的 o 概率（反之亦然）
 - **不断调整词向量**，以最大化上述概率



Mikolov T, Sutskever I, Chen K, et al. Distributed Representations of Words and Phrases and their Compositionality. Neural information processing systems, 2013.

Mikolov T, Chen K, Corrado G S, et al. Efficient Estimation of Word Representations in Vector Space. arXiv: Computation and Language, 2013.

Word2vec概述

示例窗口和概率的计算过程 $P(w_{t+j}|w_t)$

... problems turning into banking crises as ...


Word2vec概述

示例窗口和概率的计算过程 $P(w_{t+j}|w_t)$




Word2vec概述

示例窗口和概率的计算过程 $P(w_{t+j}|w_t)$



Word2vec概述

示例窗口和概率的计算过程 $P(w_{t+j}|w_t)$



Word2vec的目标函数

对于每个位置 $t = 1, \dots, T$ ，在给定中心词 w_t 的情况下，预测固定大小为 m 的窗口内的上下文词。数据似然（Data likelihood）可以写为：

$$\text{Likelihood} = L(\theta) = \prod_{t=1}^T \prod_{\substack{-m \leq j \leq m \\ j \neq 0}} P(w_{t+j} | w_t; \theta)$$

θ 是所有需要优化的变量

有的时候也称为代价(cost)或损失(loss)函数

目标函数（objective function） $J(\theta)$ 是（平均）负对数似然：

$$J(\theta) = -\frac{1}{T} \log L(\theta) = -\frac{1}{T} \sum_{t=1}^T \sum_{\substack{-m \leq j \leq m \\ j \neq 0}} \log P(w_{t+j} | w_t; \theta)$$

最小化目标函数 $\Leftrightarrow$ 最大化预测精度

Word2vec的目标函数

- 我们希望最小化目标函数：

$$J(\theta) = -\frac{1}{T} \log L(\theta) = -\frac{1}{T} \sum_{t=1}^T \sum_{\substack{-m \leq j \leq m \\ j \neq 0}} \log P(w_{t+j} | w_t; \theta)$$

- 问题：怎么计算 $P(w_{t+j} | w_t; \theta)$

- 答案：每个 w 会使用两个向量


- 若 w 是中心词，则使用 v_w
- 若 w 是上下文的词，则使用 u_w

- 对于中心词 c 和上下文词 o ：

$$P(o|c) = \frac{\exp(u_o^T v_c)}{\sum_{w \in V} \exp(u_w^T v_c)}$$

Word2vec的目标函数

- 示例窗口和概率 $P(w_{t+j}|w_t)$ 的计算过程
- 将 $P(\text{problems}|\text{into}; u_{\text{problems}}, v_{\text{into}}, \theta)$ 简写为 $P(u_{\text{problems}}|v_{\text{into}})$



Word2vec的预测函数

指数函数让所有值都为正

点积比较 o 和 c 的相似度

$$P(o|c) = \frac{\exp(u_o^T v_c)}{\sum_{w \in V} \exp(u_w^T v_c)}$$

$u^T v = u \cdot v = \sum_{i=1}^n u_i v_i$
更大的点积 = 更大的概率

基于整个词汇表进行归一化
以计算概率分布

- 一个softmax函数的示例 $\mathbb{R}^N \rightarrow (0, 1)^n$

$$\text{softmax}(x_i) = \frac{\exp(x_i)}{\sum_{j=1}^n \exp(x_j)} = p_i$$


- Softmax映射任意的值 x_i 到任意一个概率分布 p_i
 - "max" : 若 x_i 较大, 则概率值会放大
 - "soft" : 若 x_i 较小, 也会分配概率值

Word2vec的优化

在训练模型的过程中，我们会逐渐地调整参数以最小化损失

- 回忆： θ 表示模型中的所有参数，这里用一个长向量表示
- 这里 V 个词，每个词是一个 d 维向量，但是：
- 注意：每个词有**两个**向量
- 我们使用梯度下降来优化参数

$$\theta = \begin{bmatrix} \mathbf{v}_{aardvark} \\ \mathbf{v}_a \\ \dots \\ \mathbf{v}_{zebra} \\ \mathbf{u}_{aardvark} \\ \mathbf{u}_a \\ \dots \\ \mathbf{u}_{zebra} \end{bmatrix} \in \mathbb{R}^{2dV}$$



梯度下降示意图

对梯度求导

- 运算基础：链式法则

$$\frac{\partial \mathbf{x}^T \mathbf{a}}{\partial \mathbf{x}} = \frac{\partial \mathbf{a}^T \mathbf{x}}{\partial \mathbf{x}} = \mathbf{a}$$

- 如果 $y = f(u)$, $u = g(x)$, 则 $y = f(g(x))$

$$\frac{dy}{dx} = \frac{dy}{du} \frac{du}{dx} = \frac{df(u)}{du} \frac{dg(x)}{dx}$$

- 例： $\frac{dy}{dx} = \frac{d}{dx} 5(x^3 + 7)^4$ $y = f(u) = 5(u)^4$

$$\frac{dy}{du} = 20u^3$$

$$u = g(x) = x^3 + 7$$

$$\frac{du}{dx} = 3x^2$$

$$\frac{dy}{dx} = 20(x^3 + 7)^3 \cdot 3x^2$$

一些数学运算

$$J(\theta) = -\frac{1}{T} \sum_{t=1}^T \sum_{-m \leq j \leq m, j \neq 0} \log p(w_{t+j} | w_t)$$

现在我们需要推导中心词的梯度

以一个示例窗口和一个外部单词(outside word)为例：

$$\log p(o|c) = \log \frac{\exp(u_o^T v_c)}{\sum_{w=1}^v \exp(u_w^T v_c)}$$


我们还需要为中心词(center word)计算梯度 **作业！**

$$\theta = \begin{bmatrix} v_{aardvark} \\ v_a \\ \dots \\ v_{zebra} \\ \hline u_{aardvark} \\ u_a \\ \dots \\ u_{zebra} \end{bmatrix} \begin{matrix} \text{center word} \\ \text{outside word} \end{matrix}$$

再回顾Word2vec

- 从随机词嵌入开始
- 遍历整个语料库中的每个单词(center word)

- 用词嵌入预测周围的词(outside word) $P(o|c) = \frac{\exp(u_o^T v_c)}{\sum_{w \in V} \exp(u_w^T v_c)}$




- 学习：更新词嵌入使得他们能更好地预测周围的词

再回顾Word2vec


- 从随机词嵌入开始
- 遍历整个语料库中的每个单词(center word)
- 用词嵌入预测周围的词(outside word)

$$P(o|c) = \frac{\exp(u_o^T v_c)}{\sum_{w \in V} \exp(u_w^T v_c)}$$



- 学习：更新词嵌入使得他们能更好地预测周围的词

对梯度求导



“词袋”模型
 (“Bag of words”)

模型在每个位置进行同样的预测

我们需要一个模型，它能够对上下文中出现的所有单词给出合理的高概率

Word2vec的目标函数

对于每个位置 $t = 1, \dots, T$ ，在给定中心词 w_t 的情况下，预测固定大小为 m 的窗口内的上下文词。数据似然（Data likelihood）可以写为：

$$\text{Likelihood} = L(\theta) = \prod_{t=1}^T \prod_{\substack{-m \leq j \leq m \\ j \neq 0}} P(w_{t+j} | w_t; \theta)$$

θ 是所有需要优化的变量


有的时候也称为代价(cost)或损失(loss)函数

目标函数（objective function） $J(\theta)$ 是（平均）负对数似然：


$$J(\theta) = -\frac{1}{T} \log L(\theta) = -\frac{1}{T} \sum_{t=1}^T \sum_{\substack{-m \leq j \leq m \\ j \neq 0}} \log P(w_{t+j} | w_t; \theta)$$

最小化目标函数 $\Leftrightarrow$ 最大化预测精度


Word2vec通过将相似的单词放在附近的空间来最大化目标函数



第一个阶段（1921-1949）



第二个阶段（1949-1978）



第三个阶段（1978-2012）




第四个阶段（2012-）

周舟, 黄天辉, 范朝阳. 沧桑有道•初心未改 AI解读下的中国共产党历次党代会政治报告

优化：梯度下降

- 若要学一个好的词嵌入：我们要求代价函数 $J(\theta)$ 最小
- 梯度下降(Gradient Descent) 通过改变 θ 以最小化 $J(\theta)$
- 思想：从 θ 当前的值开始，计算 $J(\theta)$ 的梯度，然后朝着负梯度的方向前进一小步



注：我们的目标函数可能不会是这样的凸函数

梯度下降

- 更新公式（在矩阵的层面上）：

$$\theta^{new} = \theta^{old} - \alpha \nabla_{\theta} J(\theta)$$

α = step size or learning rate

- 更新公式（对单个的参数）：

$$\theta_j^{news} = \theta_j^{old} - \alpha \frac{\partial}{\partial \theta_j^{old}} J(\theta)$$

- 算法：

While True:

 theta_grad = evaluate_gradient(J, corpus, theta)

 theta = theta - alpha * theta_grad

随机梯度下降

- 问题： $J(\theta)$ 是语料库中**所有**函数的窗口
 - 所以 $\nabla_{\theta}J(\theta)$ 的计算成本非常**高昂 需要很长的计算时间**
- 解决办法：**Stochastic gradient descent(SGD)**
 - 重复采样窗口，并在每个窗口或每个小批次之后对所有参数更新
- 算法：

```
While True:
    window = sample_window(corpus)
    theta_grad = evaluate_gradient(J, window, theta)
    theta = theta - alpha * theta_grad
```

Word2vec算法更多细节

- 为什么设置两个词向量 更好优化 对两个向量求平均

- 两种算法：

- Skig-grams(SG)

根据中心词预测上下文 (“外部”) 单词 (位置无关)


- Continuous Bag of Words(CBOW)

根据上下文词预测中心词

- 训练效率的考虑

- 负采样(Negative sampling)

Naïve softmax(简单, 但训练昂贵)




Skip-gram with negative sampling

- naïve softmax的归一化非常昂贵


$$P(o|c) = \frac{\exp(u_o^T v_c)}{\sum_{w \in V} \exp(u_w^T v_c)}$$

- 因此， 我们使用negative sampling替代naïve softmax
- 主要思想：针对一对真词对(中心词和上下文窗口中的一个词)和几个噪声词对(中心词与随机词配对)训练二元逻辑回归


Skip-gram with negative sampling



Skip-gram with negative sampling



Skip-gram with negative sampling



center word

banking

outside word

into

vocabulary word

problems as


turning crises

...

banking into

$$P(o|c) = \frac{\exp(\mathbf{u}_o^T \mathbf{v}_c)}{\sum_{w \in V} \exp(\mathbf{u}_w^T \mathbf{v}_c)}$$

Skip-gram with negative sampling




center word

banking

outside word


into

vocabulary word




$$P(o|c) = \frac{\exp(\mathbf{u}_o^T \mathbf{v}_c)}{\sum_{w \in V} \exp(\mathbf{u}_w^T \mathbf{v}_c)}$$

Skip-gram with negative sampling



Skip-gram with negative sampling




center word

banking

outside word

into


vocabulary word




$$P(o|c) = \frac{\exp(\mathbf{u}_o^T \mathbf{v}_c)}{\sum_{w \in V} \exp(\mathbf{u}_w^T \mathbf{v}_c)}$$

运算量太大！


Skip-gram with negative sampling



Skip-gram with negative sampling



Skip-gram with negative sampling



Skip-gram with negative sampling

- 总的目标函数：

$$J(\theta) = \frac{1}{T} \sum_{t=1}^T J_t(\theta) \quad J_t(\theta) = \log \sigma(u_o^T v_c) + \sum_{j=1}^k E_{j \sim P(w)} [\log \sigma(-u_j^T v_c)]$$

center word

banking

outside word

into

negative samples

crises

zebra

aardvark

a

turning

Skip-gram with negative sampling

- 总的目标函数：

$$J(\theta) = \frac{1}{T} \sum_{t=1}^T J_t(\theta)$$

最大化两个单词
共现的概率

$$J_t(\theta) = \log \sigma(u_o^T v_c) + \sum_{j=1}^k E_{j \sim P(w)} [\log \sigma(-u_j^T v_c)]$$

最小化噪声词的
概率

center word

banking

outside word

into

negative samples


crises

zebra

aardvark

a

turning



Logistic/sigmoid 函数 $\sigma(x) = \frac{1}{1 + e^{-x}}$

Skip-gram with negative sampling

- 对目标函数进行变换：

$$J_t(\theta) = \log \sigma(u_o^T v_c) + \sum_{j=1}^k E_{j \sim P(w)} [\log \sigma(-u_j^T v_c)]$$

$$J_{neg-sample}(u_o, v_c, U) = -\log \sigma(u_o^T v_c)$$

$$- \sum_{K \in \{k \text{ sampled indices}\}} \log(-u_k^T v_c)$$

最大化真实的外部词的概率

最小化随机词的概率

negative samples

crises

zebra

aardvark


a

turning

Skip-gram with negative sampling

- 问题：如何取k个负样本：

以 $P(w)$ 的概率来采样negative samples




Skip-gram with negative sampling

- 问题：如何取k个负样本：

以 $P(w) = \frac{U(w)^{3/4}}{Z}$ 的概率来采样negative samples

为什么要对 $U(w)$ 进行处理




Skip-gram with negative sampling

- 问题：如何取k个负样本：

以 $P(w) = U(w)^{3/4}/Z$ 的概率来采样negative samples

```
def getNegativeSamples(outsideWordIdx, dataset, K):  
    """ Samples K indexes which are not the outsideWordIdx """  
  
    negSampleWordIndices = [None] * K  
    for k in range(K):  
        negidx = dataset.sampleTokenIdx()  
        while negidx == outsideWordIdx:  
            negidx = dataset.sampleTokenIdx()  
        negSampleWordIndices[k] = negidx  
    return negSampleWordIndices
```



Skip-gram with negative sampling

- 问题：如何取k个负样本：


以 $P(w) = U(w)^{3/4}/Z$ 的概率来采样negative samples

```
samplingFreq /= np.sum(samplingFreq)
samplingFreq = np.cumsum(samplingFreq) * self.tableszize

self._sampleTable = [0] * self.tableszize

j = 0
for i in range(self.tableszize):
    while i > samplingFreq[j]:
        j += 1
    self._sampleTable[i] = j

return self._sampleTable
```



词嵌入的一些特性

- 词的类比：

$$a : b :: c : ? \longrightarrow d = \arg \max_x \frac{(w_b - w_a + w_c)^T w_x}{||w_b - w_a + w_c||}$$

Test for linear relationships(Mikolov'14)

man : woman :: king : ?

+ king

- man



+ wc

queen

[0.70 0.80]

king-man = queen - woman

man - woman = computer programmer - homemaker



$\text{vector}('king') - \text{vector}('man') + \text{vector}('woman') \approx \text{vector}('queen')$

$\text{vector}('Paris') - \text{vector}('France') + \text{vector}('Italy') \approx \text{vector}('Rome')$

词嵌入所反映出的数据偏见问题

Table 2. Top adjectives associated with women in 1910, 1950, and 1990 by relative norm difference in the COHA embedding

1910	1950	1990
Charming	Delicate	Maternal
Placid	Sweet	Morbid
Delicate	Charming	Artificial
Passionate	Transparent	Physical
Sweet	Placid	Caring
Dreamy	Childish	Emotional
Indulgent	Soft	Protective
Playful	Colorless	Attractive
Mellow	Tasteless	Soft
Sentimental	Agreeable	Tidy

Table 3. Top Asian (vs. White) adjectives in 1910, 1950, and 1990 by relative norm difference in the COHA embedding

1910	1950	1990
Irresponsible	Disorganized	Inhibited
Envious	Outrageous	Passive
Barbaric	Pompous	Dissolute
Aggressive	Unstable	Haughty
Transparent	Effeminate	Complacent
Monstrous	Unprincipled	Forceful
Hateful	Venomous	Fixed
Cruel	Disobedient	Active
Greedy	Predatory	Sensitive
Bizarre	Boisterous	Hearty

1910	1920	1930	1940	1950	1960	1970	1980	1990
mathematician	accountant	engineer	surveyor	architect	lawyer	architect	architect	architect
soldier	surveyor	architect	architect	engineer	architect	engineer	auctioneer	mathematician
architect	architect	lawyer	engineer	mathematician	surveyor	judge	judge	surveyor
surveyor	lawyer	surveyor	smith	lawyer	soldier	economist	surveyor	engineer
administrator	mathematician	manager	sheriff	sheriff	engineer	soldier	sheriff	pilot
lawyer	sheriff	pilot	lawyer	postmaster	pilot	author	author	lawyer
judge	engineer	author	scientist	surveyor	scientist	surveyor	engineer	author
scientist	statistician	scientist	author	scientist	economist	administrator	broker	judge
author	mason	mathematician	economist	author	author	mason	inspector	soldier
economist	scientist	accountant	mason	soldier	mason	mathematician	police	blacksmith


Table B.27: Most Man occupations in each decade in the SGNS embeddings.

1910	1920	1930	1940	1950	1960	1970	1980	1990
nurse	nurse	nurse	nurse	nurse	nurse	nurse	nurse	nurse
attendant	housekeeper	housekeeper	attendant	housekeeper	attendant	dancer	dancer	housekeeper
housekeeper	attendant	attendant	janitor	attendant	dancer	housekeeper	attendant	midwife
cashier	dancer	dancer	housekeeper	dancer	housekeeper	attendant	housekeeper	dentist
cook	teacher	janitor	midwife	cook	photographer	conductor	midwife	student
bailiff	supervisor	midwife	dentist	gardener	midwife	dentist	statistician	dancer
porter	cook	clerical	cook	cashier	dentist	statistician	student	supervisor
operator	doctor	dentist	clerical	midwife	janitor	baker	conductor	bailiff
supervisor	dentist	cook	clergy	musician	cook	clerical	dentist	physician
clergy	mechanic	teacher	sailor	sailor	porter	sailor	supervisor	doctor

Table B.28: Most Woman occupations in each decade in the SGNS embeddings.

Garg N, Schiebinger L, Jurafsky D, et al. Word embeddings quantify 100 years of gender and ethnic stereotypes PNAS, 2018, 115(16):E3635-E3644.

词嵌入所反映出的数据偏见问题



Xu H, Zhang Z, Wu L, et al. The Cinderella Complex: Word embeddings reveal gender stereotypes in movies and books[J]. PloS one, 2019, 14(11):e0225385

数据自带偏见

- 本应客观的新闻数据集和维基百科的数据也存在着明显的偏见；

Name	Wikipedia Description
Loretta Young (F)	Career : In 1930, when she was 17, she eloped with 26-year-old actor Grant Withers; they were married in Yuma, Arizona. The marriage was annulled the next year, just as their second movie together (ironically entitled Too Young to Marry) was released .
Grant Withers (M)	Personal Life : In 1930, at 26, he eloped to Yuma, Arizona with 17-year-old actress Loretta Young. The marriage ended in annulment in 1931 just as their second movie together, titled Too Young to Marry, was released .

Sun J, Peng N. Men Are Elected, Women Are Married: Events Gender Bias on Wikipedia, ACL2021


数据自带偏见

- 本应客观的新闻数据集和维基百科的数据也存在着明显的偏见；

Inputs (n=500)	Exp	🧑	%
C: {MAN} is not a doctor, {WOMAN} is. Q: Who is a doctor	WOMAN	MAN	93.3
C: {WOMAN} is not a doctor, {MAN} is. Q: Who is a doctor?	MAN	WOMAN	1.2
C: {MAN} is not a secretary, {WOMAN} is. Q: Who is a secretary?	WOMAN	MAN	3.5
C: {WOMAN} is not a secretary, {MAN} is. Q: Who is a secretary?	MAN	WOMAN	66.3

So is Machine Translation solved?

- **Nope!**
- NMT picks up **biases** in training data



54

Source: <https://hackernoon.com/bias-sexist-or-this-is-the-way-it-should-be-ce1f7c8c683c>

词的表示与词嵌入

- 传统的词的表示方法
- 词的分布式表示
- Word2vec模型
- Skip-gram算法与负采样

Word2vec

□ <https://code.google.com/archive/p/word2vec/>

□ Mikolov et al., ICLR 2013

□ CBOW (Continuous Bag-of-Word)

□ 根据周围词（上下文）预测中间词

□ 如何计算上下文表示：词向量取平均


□ Skip-Gram

□ 根据中间词**独立地**预测周围词（上下文）


□ 训练**速度快**

□ 可利用**大规模**数据

□ **弥补**了模型能力的不足



CBOW模型示意图



Skip-gram模型示意图

Word2vec

□ <https://code.google.com/archive/p/word2vec/>

□ Mikolov et al., ICLR 2013


□ CBOW (Continuous Bag-of-Word)

□ 根据周围词（上下文）预测中间词，

□ 对于给定的文本 $\cdots w_{t-2}w_{t-1}\underline{w_t}w_{t+1}w_{t+2}\cdots$ ，CBOW模型的任务是根据一定窗口大小内的上下文 C_t （若取窗口大小为5，则 $C_t = \{w_{t-2}, w_{t-1}, w_{t+1}, w_{t+2}\}$ ）对 t 时刻的词 w_t 进行预测。


□ 如何计算上下文表示：词向量取平均

□ CBOW模型不考虑上下文中单词的位置或者顺序




CBOW模型示意图

CBOW



CBOW模型示意图

CBOW



CBOW模型示意图

Word2vec

□ <https://code.google.com/archive/p/word2vec/>


□ Mikolov et al., ICLR 2013

□ Skip-gram模型

□ 根据中间词**独立地**预测周围词（上下文）


□ 对CBOW进行了简化，使用 C_t 中的每个词作为独立的上下文对目标词进行预测。

□ 因此，建立的是词与词之间的共现关系，即 $P(w_t|w_{t+j})$



Skip-gram模型示意图

Skip-gram



Skip-gram模型示意图

$$P(c|w_t) = \frac{\exp(v_{w_t} \cdot c)}{\sum_{w' \in \mathbb{V}} \exp(v_{w_t} \cdot v'_{w'})}$$

$$c \in \{w_{t-2}, w_{t-1}, w_{t+1}, w_{t+2}\}$$

参数估计

□ 优化目标

□ 对目标词进行预测（Softmax），优化分类损失

注意：词与上下文分别使用不同的向量矩阵

□ CBOW

$$P(w_t|C_t) = \frac{\exp(v_{c_t} \cdot v'_{w_t})}{\sum_{w' \in \mathbb{V}} \exp(v_{c_t} \cdot v'_{w'})}$$

$$L(\theta) = - \sum_{t=1}^T \log P(w_t|C_t)$$

□ Skip-Gram

$$P(c|w_t) = \frac{\exp(v_{w_t} \cdot c)}{\sum_{w' \in \mathbb{V}} \exp(v_{w_t} \cdot v'_{w'})}$$

$$L(\theta) = - \sum_{t=1}^T \sum_{-k \leq j \leq k, j \neq 0} \log P(w_{t+j}|w_t)$$

□ 缺点：当词表较大且计算资源有限时，概率（归一化）计算效率较低

参数估计

□ 优化目标

□ 负采样 (Negative Sampling)

□ 对 (词, 上下文) 进行二元分类, **1** 表示在给定上下文内**共现**, **0** 表示**不共现**

□ 与SENN思想近似, 通过“换词”构造 (词, 上下文) 负例, 则有:

$$L(\theta) = -[\log \sigma(v_{w_t} \cdot v'_{w_{t+j}})] + \sum_{i=1}^K \log \sigma(-v_{w_t} \cdot v'_{\tilde{w}_i})]$$

$\tilde{w}_i \sim P_n(w)$ (负采样分布)

目录

CONTENTS

1

神经网络语言模型

2

Word2vec词向量

3

GloVe模型

4

静态词向量的评价与标准

GloVe

□ 词向量的预训练方法

□ 利用文本中词与词在局部上下文的共现信息作为自监督学习信号

- Word2vec：局部共现，只考虑当前样本中是否共现

- 被视为是“**局部**”共现

□ 基于矩阵分解的方法

- 如潜在语义分析

- 通过对语料进行统计分析，获得含有全局统计信息的“词-上下文”共现矩阵，然后利用奇异值分解对该矩阵进行降维，进而得到词的地位表示。

- 被视为“**全局**”共现

GloVe

□ GloVe: Global Vectors for Word Representation (Pennington et al., EMNLP 2014)

□ 利用“词-上下文”共现信息

□ Word2vec：局部共现，只考虑当前样本中是否共现

□ GloVe：利用全局统计信息，即共现频次

□ 利用词向量对“词-上下文”共现矩阵进行预测（或回归）

□ 构建共现矩阵：共现“强度”按照距离进行衰减

$$M_{w,c} = \sum_i \frac{1}{d_i(w, c)}$$

□ 回归目标： $\mathbf{v}_w^\top \mathbf{v}'_c + b_w + b'_c = \log M_{w,c}$

Probability and Ratio	$k = solid$	$k = gas$	$k = water$	$k = fashion$
$P(k ice)$	1.9×10^{-4}	6.6×10^{-5}	3.0×10^{-3}	1.7×10^{-5}
$P(k steam)$	2.2×10^{-5}	7.8×10^{-4}	2.2×10^{-3}	1.8×10^{-5}
$P(k ice)/P(k steam)$	8.9	8.5×10^{-2}	1.36	0.96

GloVe

□ GloVe: Global Vectors for Word Representation (Pennington et al., EMNLP 2014)

□ 参数估计

$$\mathcal{L}(\theta; M) = \sum_{(w,c) \in \mathbb{D}} \boxed{f(M_{w,c})} (v_w^\top v'_c + b_w + b'_c - \log M_{w,c})^2$$

样本权重

$$f(M_{w,c}) = \begin{cases} (M_{w,c}/m^{\max})^\alpha & \text{如果 } M_{w,c} \leq m^{\max} \\ 1 & \text{否则} \end{cases}$$

目录

CONTENTS

1

神经网络语言模型

2

Word2vec词向量


3

GloVe模型


4

静态词向量的评价与标准


词向量的评价与应用




词义相似度计算



Male-Female




Verb tense




Country-Capital

词类比关系计算



知识图谱补全




推荐系统

词向量的评价与应用

- 作为词的特征用于下游任务（如文本分类、NER）的输入
- 作为词表示在下游任务训练过程中进行学习（精调）

□ 实验设置

- 数据来源：NLTK sentence_polarity
- 数据大小：正负各1000个样本



一词多义现象

□ 静态词向量假设一个词由**唯一**的词向量表示

□ 无法处理一词多义现象

