

经典的机器学习算法


主要内容

- 人工智能和机器学习的基本概念
- 自然语言处理中常用的机器学习模型
 - 朴素贝叶斯
 - 逻辑斯谛回归
 - LDA
 - K均值聚类算法
- 常用的评价指标

主要内容

- 人工智能和机器学习的基本概念
- 自然语言处理中常用的机器学习算法
 - 朴素贝叶斯
 - 逻辑斯谛回归
 - LDA
 - K均值聚类算法
- 常用的评价指标

人工智能、机器学习与深度学习



人工智能：努力将通常由人类完成的智力任务自动化。


符号人工智能
(专家系统)

机器学习

学习：如果一个系统能够通过执行某个过程改进它的性能

赫尔伯特·西蒙

人工智能、机器学习与深度学习



人工智能：努力将通常由人类完成的智力任务自动化。


符号人工智能
(专家系统)

机器学习


学习：如果一个系统能够通过执行某个过程改进它的性能

赫尔伯特·西蒙

分析机



十九世纪三十年代，查尔斯·巴贝奇，发明了分析机（Analytical Engine），即第一台通用的机械式计算机。



COMPUTING MACHINERY AND INTELLIGENCE

By A. M. Turing

1. The Imitation Game

I propose to consider the question, "Can machines think?" This should begin with definitions of the meaning of the terms "machine" and "think." The definitions might be framed so as to reflect so far as possible the normal use of the words, but this attitude is dangerous. If the meaning of the words "machine" and "think" are to be found by examining how they are commonly used it is difficult to escape the conclusion that the meaning and the answer to the question, "Can machines think?" is to be sought in a statistical survey such as a Gallup poll. But this is absurd. Instead of attempting such a definition I shall replace the question by another, which is closely related to it and is expressed in relatively unambiguous words.

The new form of the problem can be described in terms of a game which we call the 'imitation game.' It is played with three people, a man (A), a woman (B), and an interrogator (C) who may be of either sex. The interrogator stays in a room apart from the other two. The object of the game for the interrogator is to determine which of the other two is the man and which is the woman. He knows them by labels X and Y, and at the end of the game he says either "X is A and Y is B" or "X is B and Y is A." The interrogator is allowed to put questions to A and B thus:

C: Will X please tell me the length of his or her hair?

Now suppose X is actually A, then A must answer. It is A's object in the game to try and cause C to make the wrong identification. His answer might therefore be:

"My hair is shingled, and the longest strands are about nine inches long."

In order that tones of voice may not help the interrogator the answers should be written, or better still, typewritten. The ideal arrangement is to have a teleprinter communicating between the two rooms. Alternatively the question and answers can be repeated by an intermediary. The object of the game for the third player (B) is to help the interrogator. The best strategy for her is probably to give truthful answers. She can add such things as "I am the woman, don't listen to him!" to her answers, but it will avail nothing as the man can make similar remarks.


We now ask the question, "What will happen when a machine takes the part of A in this game?" Will the interrogator decide wrongly as often when the game is played like this as he does when the game is played between a man and a woman? These questions replace our original, "Can machines think?"

2. Critique of the New Problem

As well as asking, "What is the answer to this new form of the question," one may

图灵

1950年，阿兰·图灵发表了具有里程碑意义的论文“计算机器和智能”



图片来自维基


机器学习：一种新的编程范式



机器学习系统是**训练**出来的，而不是明确地用程序编写出来的。

对于某类任务**T**和性能度量**P**，如果一个计算机程序在T上以P衡量的性能随着经验**E**而自我完善，那么我们称这个计算机程序在经验E中学习。

数据



三大要素：

输入数据点

+


预期输出的示例

+


衡量算法效果的
好坏

机器学习模型将输入数据变换为有意义的输出，这是一个从已知的输入和输出示例中进行“**学习**”的过程。因此，机器学习和深度学习的核心问题在于**有意义地变换数据**，换句话说，在于学习输入数据的有用**表示**。


(1) 原始数据



(2) 坐标变换




(3) 更好的数据表示



机器学习中的**学习**指的是，寻找更好数据表示的自动搜索过程。


机器学习的技术定义：在预先定义好的可能性空间中，利用**反馈信号**的指引来寻找输入数据的有用表示。

用三张图理解机器学习




学习的意思是为神经网络的所有层找到一组**权重值（参数）**，使得该网络能够将每个示例输入与其目标正确地一一对应。

用三张图理解机器学习




我们用损失值来衡量该网络在这个示例上的效果好坏。

用三张图理解机器学习



深度学习的基本技巧是利用距离值作为反馈信号来对权重值进行微调,以降低当前示例对应的损失值。

用三张图理解机器学习



机器学习中的基本概念

- 数据
- 模型
- 损失函数
- 训练
- 训练误差
- 测试误差


机器学习中的基本概念

- 数据



左图：著名的图像数据集ImageNet

右图：斯坦福大学的机器阅读理解数据集



机器学习中的基本概念

- 模型
- 损失函数 模型的输出和真实值之间的误差
- 训练 通过最小化损失函数来寻找最优参数
- 训练误差 模型在训练集上的误差
- 测试误差 模型在没见过的新数据上的误差

机器学习中的四类问题

- 按学习结果分类


预测	一般用回归等模型。
聚类	如K-means方法
分类	如支持向量机、逻辑斯蒂回归
降维	如主成分分析

机器学习中的四类问题

- 按学习方法分类


监督学习	如深度学习。
无监督学习	如聚类
半监督学习	介于监督和无监督学习间
强化学习	从环境中学习

监督学习任务的基本框架



机器学习中的基本概念

- 除了分类问题以外，常见的还有回归预测
 - 回归与分类的区别在于，预测的目标是连续的变量
- 无监督学习即在没有人工标记的情况下，计算机进行预测、分类等工作
- 半监督介于两者之间，增强学习更为复杂




NLP里常见的机器学习算法

- 文本分类
- 特征提取
- 标注
- 搜索与排序
- 推荐系统
- 序列学习

文本分类

- 文本分类是指在给定分类体系，根据文本内容自动确定文本类别的过程。
- 最基础的分类是归到两个类别中，称为二分类（Binary Classification）



文本分类的大致步骤

定义阶段	定义数据以及分类体系，具体分为哪些类别，需要哪些数据。
数据预处理	对文档做分词、去停用词等准备工作。
数据提取特征	对文档矩阵进行降维，提取训练集中最有用的特征。
模型训练阶段	选择具体的分类模型以及算法，训练出文本分类器。
测试	在测试集上测试并评价分类器的性能。

自然语言处理中常用的特征

Bag-of-words

最原始的特征集，一个单词/分词就是一个特征。

统计信息

包括Term frequency(TF)、Inverse document frequency(IDF)等。

N-gram

考虑了词汇顺序的模型。

标注



Label Distribution	Count	Label	Description	ICC	Gen
25.4% 	2,120	Growth Mindset	Viewing a challenging event as an opportunity for the author specifically to grow or improve themselves.	0.59	3.77
19.5% 	1,625	Impermanence	Saying bad things don't last forever, will get better soon, and/or that others have experienced similar struggles.	0.60	4.03
36.1% 	3,015	Neutralizing	Replacing a negative word with a neutral word. For example, "This was a terrible day" becomes "This was a long day."	0.32	3.53
48.7% 	4,069	Optimism	Focusing on things about the situation itself, in that moment, that are good (not just forecasting a better future).	0.44	3.89
10.1% 	841	Self-affirmation	Talking about what strengths the author already has, or the values they admire, like love, courage, perseverance, etc.	0.42	3.75
13.0% 	1,085	Thankfulness	Expressing thankfulness or gratitude with key words like appreciate, glad that, thankful for, good thing, etc.	0.68	3.95

Table 1: Summary statistics for POSITIVE PSYCHOLOGY FRAMES. (Left) Distribution of the non-exclusive labels across all 8,349 annotations shows a preference for *optimism* and *neutralizing* strategies. (Right) The quality of annotations is shown by moderate Intra-class Correlation (ICC), with reasonable *genuineness* (Gen) metrics for 100 randomly sampled datapoints.

Ziems, Caleb, Li, Minzhi, Zhang, Anthony, Yang, Diyi Inducing Positive Perspectives with Text Reframingm, ACL2022

搜索与排序

江西师范大学

百度一下

百度首页 设置

[网页](#) [图片](#) [贴吧](#) [视频](#) [资讯](#) [知道](#) [文库](#) [地图](#) [采购](#) [更多](#)



江西师范大学

[江西](#) [师范类](#) [公办](#)

[百度百科](#) 江西师范大学（Jiangxi Normal University），位于江西省南昌市，是教育部、江西省人民政府共建高校和中西部高校基础能力建设工程高校，入选全... [了解更多>](#)

 24万人正在江西师范大学贴吧讨论 >

高考主会场



只有自己亲身经历了

推荐系统

Q 周海媚抢救病历疑被泄露 | 江苏11岁



关注 **推荐** 热榜 视频 南昌 小说 三

划重点！中央经济工作会议要点梳理

置顶 央视新闻 182评论

习近平同越共中央总书记阮富仲举行会谈

置顶 央视新闻 1266评论

16位越共中央政治局委员全部到场

置顶 央视新闻 1701评论

视频|凡人微光 | 暖暖“隔代亲”

新华社 22评论

这些疫苗接种知识请知悉

金台资讯 7评论



淘宝精选

由淘宝精选推荐的广告

戒美【ZZ1103218】23AW 高频出镜单品！



序列学习

语音识别

输入为声音，输出为对通过麦克风所说的话的文本转录。

文本转语音

输入是一个文本序列，输出才是声音序列。

机器翻译

把一段话从一种语言翻译成另一种语言。

今晚的月色真美

NLP中常用的机器学习模型

- 有监督的模型
 - 朴素贝叶斯方法
 - 逻辑斯蒂回归
- 无监督的模型
 - LDA
 - K均值聚类

主要内容

- 人工智能和机器学习的基本概念
- 自然语言处理中常用的机器学习模型
 - 朴素贝叶斯
 - 逻辑斯谛回归
 - LDA
 - K均值聚类算法
- 常用的评价指标

朴素贝叶斯方法

- 朴素贝叶斯方法是基于**贝叶斯定理**与**特征条件独立假设**的分类方法, 对于给定的训练集合：
 - 首先基于特征条件独立（所以叫朴素版的贝叶斯）学习输入、输出的联合概率分布；
 - 然后基于此模型，对于给定输入 x ，利用贝叶斯定理求出后验概率最大的输出 y

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

朴素贝叶斯方法

- 设输入空间 $\mathcal{X} \subseteq R^n$ 为 n 维向量的集合，输出空间为类标记集合 $\mathcal{Y} = \{c_1, c_2, \dots, c_K\}$ ，输入为特征向量 $x \in \mathcal{X}$ ，输出为类的标记 $y \in \mathcal{Y}$ 。
- X 是定义在输入空间 $\mathcal{X}$ 上的随机向量， Y 是定义在输出空间 $\mathcal{Y}$ 上的随机变量。
- **$P(X, Y)$ 是 X 和 Y 的联合概率分布。**
- 训练数据集为： $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ ，由 $P(X, Y)$ 独立同分布产生。

朴素贝叶斯方法

- 朴素贝叶斯通过训练集合学习联合概率分布 $P(X, Y)$ 。具体地，通过学习先验概率分布及条件概率分布，从而学到联合概率分布 $P(X, Y)$ 。

先验概率分布

$$P(Y = c_k) \quad k = 1, 2, \dots, K$$

条件概率分布

$$P(X = x|Y = c_k) = P(X^{(1)} = x^{(1)}, \dots, X^{(n)} = x^{(n)}|Y = c_k)$$

联合概率分布

$$P(X, Y) = P(X = x|Y = c_k)P(Y = c_k)$$

条件概率 $P(X = x|Y = c_k)$ 有指数级数量的参数 😂😂😂

朴素贝叶斯方法

- 朴素贝叶斯法于是对条件概率分布作了条件独立性的假设。由于这个假设太强，所以朴素贝叶斯也由此得名 (**Naïve Bayes**)
- 具体而言，条件独立性假设是：

$$P(X = x|Y = c_k) = P(X^{(1)} = x^{(1)}, \dots, X^{(n)} = x^{(n)}|Y = c_k) = \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_k)$$

朴素贝叶斯方法

- 朴素贝叶斯法于是对条件概率分布作了条件独立性的假设。由于这个假设太强，所以朴素贝叶斯也由此得名 (**Naïve Bayes**)
- 具体而言，**条件独立性假设**是：

$$P(X = x|Y = c_k) = P(X^{(1)} = x^{(1)}, \dots, X^{(n)} = x^{(n)} | Y = c_k) = \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_k)$$

- 朴素贝叶斯法实际上学习到生成数据的机制，所以属于**生成模型**

条件独立性假设是说用于分类的特征在类确定的条件下都是条件独立的。

因而，朴素贝叶斯算法非常简单 😊 但是一定程度上牺牲了分类准确率 😞

朴素贝叶斯方法

- 朴素贝叶斯在进行分类时，对于给定的输入 x ，通过学习到的模型计算后验概率分布 $P(Y = c_k|X = x)$ ，将后验概率最大的类作为 x 的类输出。
- 后验概率的计算根据贝叶斯定理进行：

$$P(Y = c_k|X = x) = \frac{P(X = x|Y = c_k)P(Y = c_k)}{\sum_k P(X = x|Y = c_k)P(Y = c_k)}$$

- 代入前述的条件独立性假设的公式：

$$P(Y = c_k|X = x) = \frac{P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)}|Y = c^k)}{\sum_k P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)}|Y = c^k)}, \quad k = 1, 2, \dots, K$$

朴素贝叶斯方法

- 朴素贝叶斯分类器于是可以表示为：

$$y = f(x) = \arg \max_{c_k} \frac{P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c^k)}{\sum_k P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c^k)}$$



对所有的 c_k 都是相同的

$$y = f(x) = \arg \max_{c_k} P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c^k)$$

朴素贝叶斯的参数估计

- 朴素贝叶斯法中，学习意味着估计 $P(Y = c_k)$ 和 $P(X^{(j)} = x^{(j)} | Y = c_k)$
- 先验概率 $P(Y = c_k)$ 的极大似然估计是：

$$P(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k)}{N}, \quad k = 1, 2, \dots, K$$

朴素贝叶斯的参数估计

- 设第 j 个特征 $x^{(j)}$ 可能取值的集合为 $\{a_{j1}, a_{j2}, \dots, a_{jS_j}\}$, 条件概率 $P(X^{(j)} = a_{jl} | Y = c_k)$ 的极大似然估计是：

第 i 个样本的第 j 个特征

a_{jl} 是第 j 个特征可能取的第 l 个值

$$P(X^{(j)} = a_{jl} | Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k)}{\sum_{i=1}^N I(y_i = c_k)}$$

$$j = 1, 2, \dots, n, \quad l = 1, 2, \dots, S_j, \quad k = 1, 2, \dots, K$$

一个朴素贝叶斯的实例

输入：训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$, 其中 $x_i = (x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(n)})^T$, $x_i^{(j)}$ 是 i 个样本的第 j 个特征, $x_i^{(j)} \in \{a_{j1}, a_{j2}, \dots, a_{jS_j}\}$, a_{jl} 第 j 个特征可能取的第 l 个值, $j = 1, 2, \dots, n$, $l = 1, 2, \dots, S_j$, $k = 1, 2, \dots, K$; 实例 x

输出：实例 x 的分类

(1) 计算先验概率及条件概率

$$P(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k)}{N}, \quad k = 1, 2, \dots, K$$

$$P(X^{(j)} = a_{jl} | Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k)}{\sum_{i=1}^n I(y_i = c_k)}$$

$$j = 1, 2, \dots, n, \quad l = 1, 2, \dots, S_j, \quad k = 1, 2, \dots, K$$

(2) 对于给定的实例 $x_i = (x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(n)})^T$, 计算

$$P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c^k) \quad k = 1, 2, \dots, K$$

(3) 确定实例 x 的类

$$y = \arg \max_{c_k} P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c^k)$$

试由表的训练数据学习一个朴素贝叶斯分类器并确定 $x = (2, S)^T$ 的类标记 y 。
表中 $X^{(1)}, X^{(2)}$ 为特征，取值的集合分别为 $A_1 = \{1, 2, 3\}$, $A_2 = \{S, M, L\}$, Y 为类标记, $Y \in C = \{1, -1\}$

训练数据

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
$X^{(1)}$	1	1	1	1	1	2	2	2	2	2	3	3	3	3	3
$X^{(2)}$	S	M	M	S	S	S	M	M	L	L	L	M	M	L	L
Y	-1	-1	1	1	-1	-1	-1	1	1	1	1	1	1	1	-1

训练数据

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
$X^{(1)}$	1	1	1	1	1	2	2	2	2	2	3	3	3	3	3
$X^{(2)}$	S	M	M	S	S	S	M	M	L	L	L	M	M	L	L
Y	-1	-1	1	1	-1	-1	-1	1	1	1	1	1	1	1	-1

$$P(Y = 1) = \frac{9}{15} \quad P(Y = -1) = \frac{6}{15}$$

$$P(X^{(1)} = 1|Y = 1) = \frac{2}{9} \quad P(X^{(1)} = 2|Y = 1) = \frac{3}{9} \quad P(X^{(1)} = 3|Y = 1) = \frac{4}{9}$$

$$P(X^{(2)} = S|Y = 1) = \frac{1}{9} \quad P(X^{(2)} = M|Y = 1) = \frac{4}{9} \quad P(X^{(2)} = L|Y = 1) = \frac{4}{9}$$

$$P(X^{(1)} = 1|Y = -1) = \frac{3}{6} \quad P(X^{(1)} = 2|Y = -1) = \frac{2}{6} \quad P(X^{(1)} = 3|Y = -1) = \frac{1}{6}$$

$$P(X^{(2)} = S|Y = -1) = \frac{3}{6} \quad P(X^{(2)} = M|Y = -1) = \frac{2}{6} \quad P(X^{(2)} = L|Y = -1) = \frac{1}{6}$$

$$P(Y = 1) = \frac{9}{15} \quad P(Y = -1) = \frac{6}{15}$$

$$P(X^{(1)} = 1|Y = 1) = \frac{2}{9} \quad P(X^{(1)} = 2|Y = 1) = \frac{3}{9} \quad P(X^{(1)} = 3|Y = 1) = \frac{4}{9}$$

$$P(X^{(2)} = S|Y = 1) = \frac{1}{9} \quad P(X^{(2)} = M|Y = 1) = \frac{4}{9} \quad P(X^{(2)} = L|Y = 1) = \frac{4}{9}$$

$$P(X^{(1)} = 1|Y = -1) = \frac{3}{6} \quad P(X^{(1)} = 2|Y = -1) = \frac{2}{6} \quad P(X^{(1)} = 3|Y = -1) = \frac{1}{6}$$

$$P(X^{(2)} = S|Y = -1) = \frac{3}{6} \quad P(X^{(2)} = M|Y = -1) = \frac{2}{6} \quad P(X^{(2)} = L|Y = -1) = \frac{1}{6}$$

对于给定的 $x = (2, S)^T$

$$P(Y = 1)P(X^{(1)} = 2|Y = 1)P(X^{(2)} = S|Y = 1) = \frac{9}{15} \cdot \frac{3}{9} \cdot \frac{1}{9} = \frac{1}{45}$$

$$P(Y = -1)P(X^{(1)} = 2|Y = -1)P(X^{(2)} = S|Y = -1) = \frac{6}{15} \cdot \frac{2}{6} \cdot \frac{3}{6} = \frac{1}{15}$$

$$P(Y = 1) = \frac{9}{15} \quad P(Y = -1) = \frac{6}{15}$$

$$P(X^{(1)} = 1|Y = 1) = \frac{2}{9} \quad P(X^{(1)} = 2|Y = 1) = \frac{3}{9} \quad P(X^{(1)} = 3|Y = 1) = \frac{4}{9}$$

$$P(X^{(2)} = S|Y = 1) = \frac{1}{9} \quad P(X^{(2)} = M|Y = 1) = \frac{4}{9} \quad P(X^{(2)} = L|Y = 1) = \frac{4}{9}$$

$$P(X^{(1)} = 1|Y = -1) = \frac{3}{6} \quad P(X^{(1)} = 2|Y = -1) = \frac{2}{6} \quad P(X^{(1)} = 3|Y = -1) = \frac{1}{6}$$

$$P(X^{(2)} = S|Y = -1) = \frac{3}{6} \quad P(X^{(2)} = M|Y = -1) = \frac{2}{6} \quad P(X^{(2)} = L|Y = -1) = \frac{1}{6}$$

对于给定的 $x = (2, S)^T$

$$P(Y = 1)P(X^{(1)} = 2|Y = 1)P(X^{(2)} = S|Y = 1) = \frac{9}{15} \cdot \frac{3}{9} \cdot \frac{1}{9} = \frac{1}{45}$$

$$P(Y = -1)P(X^{(1)} = 2|Y = -1)P(X^{(2)} = S|Y = -1) = \frac{6}{15} \cdot \frac{2}{6} \cdot \frac{3}{6} = \frac{\mathbf{1}}{\mathbf{15}} \quad \text{所以 } \mathbf{y} = \mathbf{-1}$$

贝叶斯估计

如果某个概率为零咋办？😱😱😱

贝叶斯估计！！！！😏😏😏

- 具体地，条件概率的估计是：

$$P_{\lambda}(X^{(j)} = a_{jl} | Y = c_k) = \frac{\sum_{i=1}^n I(x_i^{(j)} = a_{jl}, y_i = c_k) + \lambda}{\sum_{i=1}^n I(y_i = c_k) + S_j \lambda}$$

$\lambda \geq 0$ 等价于在随机变量各个取值的频数上赋予一个正数 $\lambda > 0$

$\lambda = 0$ 极大似然估计

$\lambda = 1$ 拉普拉斯平滑

朴素贝叶斯的参数估计

- 对任何 $l = 1, 2, \dots, S_j$, $k = 1, 2, \dots, K$, 有

$$P_{\lambda}(X^{(j)} = a_{jl} | Y = c_k) > 0 \quad \sum_l^{S_j} P_{\lambda}(X^{(j)} = a_{jl} | Y = c_k) = 1$$

- 同时, 先验概率的贝叶斯估计是:

$$P_{\lambda}(Y = c_k) = \frac{\sum_{i=1}^n I(y_i = c_k) + \lambda}{N + K\lambda}$$

按照拉普拉斯平滑估计概率，取 $\lambda = 1$

$$\begin{aligned} P(Y = 1) &= \frac{10}{17} & P(Y = -1) &= \frac{7}{17} \\ P(X^{(1)} = 1|Y = 1) &= \frac{3}{12} & P(X^{(1)} = 2|Y = 1) &= \frac{4}{12} & P(X^{(1)} = 3|Y = 1) &= \frac{4}{12} \\ P(X^{(2)} = S|Y = 1) &= \frac{2}{12} & P(X^{(2)} = M|Y = 1) &= \frac{5}{12} & P(X^{(2)} = L|Y = 1) &= \frac{5}{12} \\ P(X^{(1)} = 1|Y = -1) &= \frac{4}{9} & P(X^{(1)} = 2|Y = -1) &= \frac{3}{9} & P(X^{(1)} = 3|Y = -1) &= \frac{2}{9} \\ P(X^{(2)} = S|Y = -1) &= \frac{4}{9} & P(X^{(2)} = M|Y = -1) &= \frac{3}{9} & P(X^{(2)} = L|Y = -1) &= \frac{2}{9} \end{aligned}$$

对于给定的 $x = (2, S)^T$

$$P(Y = 1)P(X^{(1)} = 2|Y = 1)P(X^{(2)} = S|Y = 1) = \frac{10}{17} \cdot \frac{4}{12} \cdot \frac{2}{12} = \frac{1}{153}$$

$$P(Y = -1)P(X^{(1)} = 2|Y = -1)P(X^{(2)} = S|Y = -1) = \frac{7}{17} \cdot \frac{3}{9} \cdot \frac{4}{9} = \frac{28}{459}$$

按照拉普拉斯平滑估计概率, 取 $\lambda = 1$

$$\begin{aligned} P(Y = 1) &= \frac{10}{17} & P(Y = -1) &= \frac{7}{17} \\ P(X^{(1)} = 1|Y = 1) &= \frac{3}{12} & P(X^{(1)} = 2|Y = 1) &= \frac{4}{12} & P(X^{(1)} = 3|Y = 1) &= \frac{4}{12} \\ P(X^{(2)} = S|Y = 1) &= \frac{2}{12} & P(X^{(2)} = M|Y = 1) &= \frac{5}{12} & P(X^{(2)} = L|Y = 1) &= \frac{5}{12} \\ P(X^{(1)} = 1|Y = -1) &= \frac{4}{9} & P(X^{(1)} = 2|Y = -1) &= \frac{3}{9} & P(X^{(1)} = 3|Y = -1) &= \frac{2}{9} \\ P(X^{(2)} = S|Y = -1) &= \frac{4}{9} & P(X^{(2)} = M|Y = -1) &= \frac{3}{9} & P(X^{(2)} = L|Y = -1) &= \frac{2}{9} \end{aligned}$$

对于给定的 $x = (2, S)^T$

$$P(Y = 1)P(X^{(1)} = 2|Y = 1)P(X^{(2)} = S|Y = 1) = \frac{10}{17} \cdot \frac{4}{12} \cdot \frac{2}{12} = \frac{1}{153}$$

$$P(Y = -1)P(X^{(1)} = 2|Y = -1)P(X^{(2)} = S|Y = -1) = \frac{7}{17} \cdot \frac{3}{9} \cdot \frac{4}{9} = \frac{28}{459} \text{ 所以仍然 } \mathbf{y = -1}$$

主要内容

- 人工智能和机器学习的基本概念
- 自然语言处理中常用的机器学习算法
 - 朴素贝叶斯
 - **逻辑斯谛回归**
 - LDA
 - K均值聚类算法
- 常用的评价指标

逻辑斯谛回归

- 逻辑斯谛分布：设 X 是连续随机变量， X 服从**逻辑斯谛分布**是指 X 具有下列分布函数和密度函数：

$$F(X) = P(X \leq x) = \frac{1}{1 + e^{-(x-\mu)/\gamma}}$$

$$f(X) = F'(X) = \frac{e^{-(x-\mu)/\gamma}}{\gamma[1 + e^{-(x-\mu)/\gamma}]^2}$$

μ 为位置参数， $\gamma > 0$ 为形状参数。

逻辑斯谛回归

- 二项逻辑斯谛回归模型 (binominal logistic regression model) 是一种分类模型, 由条件概率分布 $P(Y|X)$ 表示, 形式为参数化的逻辑斯谛分布。这里, 随机变量 X 取值为实数, 随机变量 Y 取值为1或0。我们通过监督学习的方法来估计模型参数。
- **二元逻辑斯谛回归模型** 是如下的条件概率分布：

$$P(Y = 1|x) = \frac{\exp(w \cdot x + b)}{1 + \exp(w \cdot x + b)} \quad P(Y = 0|x) = \frac{1}{1 + \exp(w \cdot x + b)}$$

这里, $x \in \mathcal{R}^n$ 是输入, $Y \in \{0,1\}$ 是输出, $w \in \mathcal{R}^n$ 和 $b \in \mathcal{R}$ 是参数, w 称为权值向量, b 称为偏置, $w \cdot x$ 为 w 和 x 的内积

逻辑斯谛回归

- 对于给定的输入 x ，可以由前述的公式求得 $P(Y = 1|x)$ 和 $P(Y = 0|x)$ 。逻辑斯谛回归比较两个条件概率值的大小，将实例 x 分到概率值较大的那一类。
- 有时为了方便，将权值向量和输入向量加以扩充，仍记作 w ， x ，即 $w = (w^{(1)}, w^{(2)}, \dots, w^{(n)}, b)^T$ ， $x = (x^{(1)}, x^{(2)}, \dots, x^{(n)}, 1)^T$ ，这时，逻辑斯谛回归模型如下：

$$P(Y = 1|x) = \frac{\exp(w \cdot x)}{1 + \exp(w \cdot x)}$$

$$P(Y = 0|x) = \frac{1}{1 + \exp(w \cdot x)}$$

逻辑斯蒂回归

- 一个事件的几率（odds）是指**该事件发生的概率**与**该事件不发生的概率**的比值。
- 如果事件发生的概率是 p ，那么该事件的几率是 $p/1 - p$ ，该事件的对数几率（log odds）或logit函数是

$$\text{logit}(p) = \log \frac{p}{1 - p}$$

- 对逻辑斯蒂回归模型而言，可以得到：

$$\log \frac{P(Y = 1|x)}{1 - P(Y = 1|x)} = w \cdot x$$

逻辑斯蒂回归

- 也即，在逻辑斯蒂回归模型中，输出 $Y = 1$ 的对数几率是输入 x 的线性函数。或者说，输出 $Y = 1$ 的对数几率是由输入 x 的线性函数表示的模型，即逻辑斯蒂回归模型。

- 换一个角度，考虑对输入 x 进行分类的线性函数 $w \cdot x$ ，其值域为实数域，这里 $x \in \mathcal{R}^{n+1}$ ， $w \in \mathcal{R}^{n+1}$ ，通过将线性函数 $w \cdot x$ 转换为概率：

$$P(Y = 1|x) = \frac{\exp(w \cdot x)}{1 + \exp(w \cdot x)}$$

- 这时，线性函数的值越接近正无穷，概率值就越接近1；线性函数的值越接近负无穷，概率值就越接近0。这样的模型就是逻辑斯蒂回归模型。

模型参数估计

- 逻辑斯蒂回归模型学习时，对于给定的训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ ，其中， $x_i \in \mathcal{R}^n$ ， $y_i \in \{0, 1\}$ ，可以应用极大似然估计法估计模型参数，从而得到逻辑斯蒂回归模型。

- 设： $P(Y = 1|x) = \pi(x)$ $P(Y = 0|x) = 1 - \pi(x)$

- 似然函数为：

$$\prod_{i=1}^N (\pi(x_i))^{y_i} (1 - \pi(x_i))^{1-y_i}$$

模型参数估计

- 对数似然函数为：

$$\begin{aligned} L(w) &= \sum_{i=1}^N [y_i \log \pi(x_i) + (1 - y_i) \log(1 - \pi(x_i))] \\ &= \sum_{i=1}^N \left[y_i \log \frac{\pi(x_i)}{1 - \pi(x_i)} + \log(1 - \pi(x_i)) \right] \\ &= \sum_{i=1}^N \{y_i(w \cdot x_i) - \log[1 + \exp(w \cdot x_i)]\} \end{aligned}$$

对 $L(w)$ 求极大值，得到 w 的估计值

模型参数估计

- 对数似然函数为问题变成了以对数似然函数为目标函数的最优化问题
- 假设 w 的极大似然估计值是 $\hat{w}$ ，那么学到的逻辑斯蒂回归模型为：

$$P(Y = 1|x) = \frac{\exp(\hat{w} \cdot x)}{1 + \exp(\hat{w} \cdot x)}$$

$$P(Y = 0|x) = \frac{1}{1 + \exp(\hat{w} \cdot x)}$$

多项逻辑斯谛回归

- 将二元逻辑斯谛可以推广到多项式逻辑斯谛回归模型，可用于多分类。
- 假设离散型随机变量 Y 的取值集合是 $\{1, 2, \dots, K\}$ ，那么多项逻辑斯谛回归模型是：

$$P(Y = k|x) = \frac{\exp(w_k \cdot x)}{1 + \sum_{k=1}^{K-1} \exp(w_k \cdot x)} \quad k = 1, 2, \dots, K-1$$

$$P(Y = K|x) = \frac{1}{1 + \sum_{k=1}^{K-1} \exp(w_k \cdot x)}$$


$$x \in R^{n+1}, w_k \in R^{n+1}$$

主要内容

- 人工智能和机器学习的基本概念
- 自然语言处理中常用的机器学习算法
 - 朴素贝叶斯
 - 逻辑斯谛回归
 - **LDA**
 - K均值聚类算法
- 常用的评价指标

潜在狄利克雷分配模型

- 潜在狄利克雷分配 (Latent Dirichlet Allocation, LDA) 是文本集合的生成模型。
- 模型假设话题由单词分布表示, 文本由话题的多项分布表示, 单词分布和话题分布的先验分布都是狄利克雷分布。
- 文本内容的不同是由于它们的话题不同。
- LDA 是概率图模型, 其特点是以狄利克雷分布为多项分布的先验分布, 学习就是给定文本集合, 通过后验概率分布的估计, 推断模型的所有参数。
- 利用 LDA 进行话题分析就是对给定文本集合, 学习到每个文本的话题分布, 以及每个话题的单词分布。



潜在狄利克雷分配模型

首先，基于单词分布的先验分布（狄利克雷分布）生成多个单词分布


决定多个话题内容

然后，基于话题分布的先验分布（狄利克雷分布）生成多个话题分布

决定多个文本内容

最后，基于每一个话题分布生成话题序列，针对每一个话题，基于话题的单词分布生成单词，整体构成一个单词序列

生成文本



模型定义

- 潜在狄利克雷分配 (LDA)使用三个集合：

单词集合

$W = \{w_1, w_2, \dots, w_v, \dots, w_V\}$, 其中, w_v 是第 v 个单词, $v = 1, 2, \dots, V$,
 V 是单词的个数

文本集合

$D = \{w_1, w_2, \dots, w_m, \dots, w_M\}$, 其中, w_m 是第 m 个文本, $m = 1, 2, \dots, M$,
 M 是文本的个数。文本 w_m 是一个单词序列 $w_m = \{w_{m1}, w_{m2}, \dots, w_{mn}, \dots, w_{mN_m}\}$
其中 w_{mn} 是文本 w_m 的第 n 个单词, $n = 1, 2, \dots, N_m$, N_m 是文本 w_m 的单词个数

话题集合

$Z = \{z_1, z_2, \dots, z_k, \dots, z_K\}$, 其中, z_k 是第 k 个话题, $k = 1, 2, \dots, K$,
 K 是话题的个数

文本生成过程

- 给定单词集合 W ，文本集合 D ，话题集合 Z ，狄利克雷分布的超参数 α 和 β ，LDA文本集合的生成过程如下：

生成话题的单词分布

随机生成 K 个话题的单词分布，具体过程如下：按照狄利克雷分布 $Dir(\beta)$ 随机生成一个参数向量 ϕ_k ， $\phi_k \sim Dir(\beta)$ ，作为话题 z_k 的单词分布 $P(w|z_k)$ ， $w \in W$ ， $k = 1, 2, \dots, K$

生成文本的话题分布

随机生成 M 个文本的分布，具体过程如下：按照狄利克雷分布 $Dir(\alpha)$ 随机生成一个参数向量 θ_m ， $\theta_m \sim Dir(\alpha)$ ，作为文本 w_m 的话题分布， $P(z|w_m)$ ， $m = 1, 2, \dots, M$

生成文本的单词序列

随机生成 M 个文本的 N_m 个单词。文本 $w_m (m = 1, 2, \dots, M)$ 的单词 $w_{mn} (n = 1, 2, \dots, N_m)$ 的生成过程如下：

- (a) 首先按照多项分布 $Mult(\theta_m)$ 随机生成一个话题 z_{mn} ， $z_{mn} \sim Mult(\theta_m)$ 。
- (b) 然后按照多项分布 $Mult(\psi_{z_{mn}})$ 随机生成一个单词 w_{mn} ， $w_{mn} \sim Mult(\psi_{z_{mn}})$ 。文本本身是单词序列 $w_m = \{w_{m1}, w_{m2}, \dots, w_{mN_m}\}$ ，对应着隐式的话题序列 $z_m = \{z_{m1}, z_{m2}, \dots, z_{mN_m}\}$ 。

LDA的文本生成算法

(1) 对于话题 $z_k (k = 1, 2, \dots, K)$:

生成多项分布参数 $\varphi_k \sim \text{Dir}(\beta)$, 作为话题的单词分布 $P(w|z_k)$;

(2) 对于文本 $w_m (m = 1, 2, \dots, M)$:

生成多项分布参数 $\theta_m \sim \text{Dir}(\alpha)$, 作为文本的话题分布 $P(z|w_m)$;


(3) 对于文本 w_m 的单词 $w_{mn} (m = 1, 2, \dots, M, n = 1, 2, \dots, N_m)$:

(a) 生成话题 $z_{mn} \sim \text{Mult}(\theta_m)$, 作为单词对应的话题;

(b) 生成单词 $w_{mn} \sim \text{Mult}(\varphi_{z_{mn}})$ 。

LDA的文本生成过程中, 假定话题个数 K 给定, 实际通常通过实验选定。狄利克雷分布的超参数 α 和 β 通常也是事先给定的。

概率图模型



$$P(w, z, \theta | \alpha, \beta) = \prod_{k=1}^K p(\varphi_k | \beta) \prod_{m=1}^M p(\theta_m | \alpha) \prod_{n=1}^{N_m} p(z_{mn} | \theta_m) p(w_{mn} | z_{mn}, \varphi)$$

主要内容

- 人工智能和机器学习的基本概念
- 自然语言处理中常用的机器学习算法
 - 朴素贝叶斯
 - 逻辑斯谛回归
 - LDA
 - **k均值聚类算法**
- 常用的评价指标

聚类的概念

- 聚类是针对给定的样本，根据它们特征的相似度或距离，将其归并到若干个“类”或“簇”的数据分析问题。
 - 一个类就是给定样本集合的一个子集。
 - 直观上，相似的样本聚集在相同的类，不相似的样本分散在不同的类。
- 聚类的目的是通过得到的类或簇来发现数据的特点或对数据进行处理。
- 聚类属于无监督学习，因为只是根据样本的**相似度**或**距离**将其进行归类，而类或簇事先并不知道。

相似度或距离

- 聚类的对象是观测数据，或样本集合。假设有 n 个样本，每个样本由 m 个属性的特征向量组成。

$$X = [x_{ij}]_{m \times n} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1n} \\ x_{21} & x_{22} & \cdots & x_{2n} \\ \vdots & \vdots & & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{mn} \end{bmatrix}$$

- 矩阵的第 j 列表示第 j 个样本， $j = 1, 2, \dots, n$ ，第 i 行表示第 i 个属性， $i = 1, 2, \dots, m$ ；矩阵元素 x_{ij} 表示第 j 个样本的第 i 个属性值， $i = 1, 2, \dots, m$ ； $j = 1, 2, \dots, n$ 。
- 聚类的核心概念是**相似度**（similarity）或**距离**（distance），有很多种相似度的定义。

常用的距离度量

- 闵可夫斯基距离
 - 聚类可以将样本集合看作向量空间中点的集合，以该空间的距离表示样本之间的相似度，如闵可夫斯基距离。闵可夫斯基距离越大，相似度越小；距离越小，相似度越大。

定义

给定样本集合 X ， X 是 m 维实数向量空间 $\mathcal{R}^m$ 中点的集合，其中 $x_i, x_j \in X$,

$x_i = (x_{1i}, x_{2i}, \dots, x_{mi})^T$, $x_j = (x_{1j}, x_{2j}, \dots, x_{mj})^T$, 样本 x_i 和 x_j 的闵可夫斯基距离定义为：

$$d_{ij} = \left(\sum_{k=1}^m |x_{ki} - x_{kj}|^p \right)^{1/p}$$

这里 $p \geq 1$ 。当 $p = 2$ 时称为欧式距离(Euclidean distance)，即

$$d_{ij} = \left(\sum_{k=1}^m |x_{ki} - x_{kj}|^2 \right)^{1/2}$$

常用的距离度量

- 闵可夫斯基距离
 - 聚类可以将样本集合看作向量空间中点的集合，以该空间的距离表示样本之间的相似度，如闵可夫斯基距离。闵可夫斯基距离越大，相似度越小；距离越小，相似度越大。

定义

当 $P = 1$ 时称为曼哈顿距离(Manhattan distance)，即

$$d_{ij} = \sum_{k=1}^m |x_{ki} - x_{kj}|$$

当 $P = \infty$ 时称为契比雪夫距离(Chebyshev distance)，取各个坐标数值差的绝对值的最大值，即

$$d_{ij} = \max_k |x_{ki} - x_{kj}|$$

常用的相似度量

- 相关系数

- 样本之间的相似度也可以用相关系数（correlation coefficient）来表示。相关系数的绝对值越接近于1，表示样本越相似；越接近于0，表示样本越不相似。

定义

样本 x_i 与样本 x_j 之间的相关系数定义为

$$r_{ij} = \frac{\sum_{k=1}^m (x_{ki} - \bar{x}_i)(x_{kj} - \bar{x}_j)}{[\sum_{k=1}^m (x_{ki} - \bar{x}_i)^2 \sum_{k=1}^m (x_{kj} - \bar{x}_j)^2]^{1/2}}$$

其中,

$$\bar{x}_i = \frac{1}{m} \sum_{k=1}^m x_{ki}, \quad \bar{x}_j = \frac{1}{m} \sum_{k=1}^m x_{kj}$$

相似度或距离

- 夹角余弦
 - 样本之间的相似度也可以用夹角余弦（cosine）来表示。夹角余弦越接近于1，表示样本越相似；越接近于0，表示样本越不相似。

定义

样本 x_i 与样本 x_j 之间的夹角余弦定义为

$$s_{ij} = \frac{\sum_{k=1}^m x_{ki} x_{kj}}{[\sum_{k=1}^m x_{ki}^2 \sum_{k=1}^m x_{kj}^2]^{1/2}}$$

由上述定义可看出，用距离度量相似度时，**距离越小样本越相似**，用相关系数时，**相关系数越大样本越相似**。

相似度或距离类或簇

- 通过聚类得到的类或簇，本质是样本的子集。
 - 如果一个聚类方法假定一个样本只能属于一个类，或类的交集为空集，那么该方法称为硬聚类（hard clustering）方法。否则，如果一个样本可以属于多个类，或类的交集不为空集，那么该方法称为软聚类（soft clustering）方法。
- 用 G 表示类或簇（cluster），用 x_i ， x_j 表示类中的样本，用 n_G 表示 G 中样本的个数，用 d_{ij} 表示样本 x_i 与 x_j 之间的距离。

类的定义

- 类或簇的定义有很多种

定义

设 T 为给定的正数，若集合 G 中任意两个 x_i, x_j 有

$$d_{ij} \leq T$$

则称 G 为一个类或簇。

定义

设 T 为给定的正数，若对集合 G 中任意样本 x_i ，一定存在 G 中的另一个样本 x_j ，使得

$$d_{ij} \leq T$$

则称 G 为一个类或簇。

类的定义

- 类或簇的定义有很多种

定义

设 T 为给定的正数，若对集合 G 中任意样本 x_i ， G 中的另一个样本 x_j 满足

$$\frac{1}{n_G - 1} \sum_{x_j \in G} d_{ij} \leq T$$

n_G 为 G 中样本的个数，则称 G 为一个类或簇。

定义

设 T 和 V 为给定的正数，如果集合 G 中两个样本 x_i ， x_j 的距离 d_{ij} 满足

$$\frac{1}{n_G(n_G - 1)} \sum_{x_i \in G} \sum_{x_j \in G} d_{ij} \leq T \quad d_{ij} \leq V$$

则称 G 为一个类或簇。

类的常用特征

- 类的特征可以通过不同角度来刻画，常用的有三种：

类的均值 $\bar{x}_G$ ，又称为类的中心

$$\bar{x}_G = \frac{1}{n_G} \sum_{i=1}^{n_G} x_i$$

式中 n_G 是类 G 的样本个数。

类的直径(diameter) D_G

类的直径 D_G 是类中任意两个样本之间的最大距离，即，

$$D_G = \max_{x_i, x_j \in G} d_{ij}$$

类的散布矩阵(scatter matter) A_G 与样本协方差矩阵(covariance matrix) S_G

$$A_G = \sum_{i=1}^{n_G} (x_i - \bar{x}_G)(x_i - \bar{x}_G)^T \quad S_G = \frac{1}{m-1} A_G = \frac{1}{m-1} \sum_{i=1}^{n_G} (x_i - \bar{x}_G)(x_i - \bar{x}_G)^T$$

其中 m 为样本的维数（样本属性的个数）。

类与类之间的距离

- 设类 G_p 包含 n_p 个样本, G_q 包含 n_q 个样本, 分别用 $\bar{x}_p$ 和 $\bar{x}_q$ 表示 G_p 和 G_q 的均值, 即类的中心。

最短距离或单连接(single linkage)

定义类 G_p 的样本与 G_q 的样本之间的最短距离为两类之间的距离

$$D_{pq} = \min\{d_{ij} | x_i \in G_p, x_j \in G_q\}$$

最长距离或完全连接(complete linkage)

定义类 G_p 的样本与 G_p 的样本之间的最长距离为两类之间的距离

$$D_{pq} = \max\{d_{ij} | x_i \in G_p, x_j \in G_q\}$$

类与类之间的距离

- 设类 G_p 包含 n_p 个样本, G_q 包含 n_q 个样本, 分别用 $\bar{x}_p$ 和 $\bar{x}_q$ 表示 G_p 和 G_q 的均值, 即类的中心。

中心距离

定义类 G_p 与类 G_q 的中心 $\bar{x}_p$ 与 $\bar{x}_q$ 之间的距离为两类之间的距离

$$D_{pq} = d_{\bar{x}_p \bar{x}_q}$$

平均距离

定义类 G_p 与类 G_q 任意两个样本之间距离的平均值为两类之间的距离

$$D_{pq} = \frac{1}{n_p n_q} \sum_{x_i \in G_p} \sum_{x_j \in G_q} d_{ij}$$

K均值聚类

- K均值聚类将样本集合划分到 k 个子集，构成 k 个类，将 n 个样本分到 k 个类中，每个样本到其所属类的中心的距离最小。
- 模型概述
 - 给定 n 个样本的集合 $X = \{x_1, x_2, \dots, x_n\}$ ，每个样本由一个特征向量表示，特征向量的维数是 m 。
 - k 均值聚类的目标是将 n 个样本分到 k 个不同的类或簇中，这里假设 $k < n$ 。
 - k 个类 $G_1, G_2, \dots, G_k$ 形成对样本集合 X 的划分，其中 $G_i \cap G_j = \emptyset$ ， $\bigcup_{i=1}^k G_i = X$ 。
 - 用 $\mathcal{C}$ 表示划分，一个划分对应着一个聚类结果。

K均值聚类

- k 均值聚类的策略是通过损失函数的最小化选取最优的划分或函数 C^* 。

首先，采用欧式距离平方 (squared Euclidean distance)作为样本之间的距离 $d(x_i, x_j)$

$$d(x_i, x_j) = \sum_{k=1}^m (x_{ki} - x_{kj})^2 = \|x_i - x_j\|^2$$

然后，定义样本与其所属类的中心之间的距离的总和为损失函数，即

$$W(C) = \sum_{k=1}^m \sum_{c(i)=l} \|x_i - \bar{x}_l\|^2$$

式中， $\bar{x}_l = (\bar{x}_{1l}, \bar{x}_{2l}, \dots, \bar{x}_{ml})$ 是第 l 个类的均值或中心， $n_l = \sum_{i=1}^n I(C(i) = l)$ ， $I(C(i) = l)$ 是指示函数，取值为1或0，函数 $W(C)$ 也称为能量，表示相同类中的样本相似的程度。

K均值聚类


- k 均值聚类就是求解最优化问题：

$$\begin{aligned} C^* &= \arg \min_C W(C) \\ &= \arg \min_C \sum_{l=1}^k \sum_{C(i)=l} \|x_i - \bar{x}_l\|^2 \end{aligned}$$

相似的样本被聚到同类时，损失函数值最小，这个目标函数的最优化能达到聚类的目的，但是，这是一个组合优化问题。 n 个样本分到 k 类，所有可能分法的数目是：

$$S(n, k) = \frac{1}{k!} \sum_{l=1}^k (-1)^{k-l} \binom{k}{l} k^n$$

K均值聚类算法



首先，对于给定的中心值 $(m_1, m_2, \dots, m_k)$ ，求一个划分 C ，使得目标函数最小：

$$\min_C \sum_{l=1}^k \sum_{C(i)=l} \|x_i - m_l\|^2$$

将每个样本指派到与其最近的中心 m_l 的类 G_l 中。然后，对给定的划分 C ，再求各个类的中心 $(m_1, m_2, \dots, m_k)$ ，使得目标函数极小化：

$$\min_{m_1, m_2, \dots, m_k} \sum_{l=1}^k \sum_{C(i)=l} \|x_i - m_l\|^2$$

求解结果，对于每个包含 n_l 个样本的 G_l ，更新其权值：

$$m_l = \frac{1}{n_l} \sum_{C(i)=l} x_i, \quad l = 1, 2, \dots, k$$

重复以上步骤，直到划分不再改变。

输入： n 个样本的集合 X

输出：样本集合的聚类

(1) 初始化。令 $t = 0$ 。随机选择 k 个样本点作为初始聚类中心 $m^{(0)} = (m_1^{(0)}, \dots, m_l^{(0)}, \dots, m_k^{(0)})$

(2) 对样本进行聚类。对固定的类中心 $m^{(t)} = (m_1^{(t)}, \dots, m_l^{(t)}, \dots, m_k^{(t)})$ ，其中， $m_l^{(t)}$ 为类 G_l 的中心，计算每个样本到类中心的距离，将每个样本指派到与其最近的中心的类中，构成聚类结果 $C^{(t)}$

(3) 计算新的类中心。对聚类记过 $C^{(t)}$ ，计算当前个各个类中的样本的均值，作为新的类中心 $m^{(t+1)} = (m_1^{(t+1)}, \dots, m_l^{(t+1)}, \dots, m_k^{(t+1)})$

(4) 如果迭代收敛或符合停止条件，输出 $C^* = C^{(t)}$ ；否则，令 $t = t + 1$ ，返回步骤(2)

k 均值聚类算法的复杂度是 $O(mnk)$ ，其中 m 是样本维数， n 是样本个数， k 是类别个数

输入： n 个样本的集合 X

输出：样本集合的聚类

(1) 初始化。令 $t = 0$ 。随机选择 k 个样本点作为初始聚类中心 $m^{(0)} = (m_1^{(0)}, \dots, m_l^{(0)}, \dots, m_k^{(0)})$

(2) 对样本进行聚类。对固定的类中心 $m^{(t)} = (m_1^{(t)}, \dots, m_l^{(t)}, \dots, m_k^{(t)})$ ，其中， $m_l^{(t)}$ 为类 G_l 的中心，计算每个样本到类中心的距离，将每个样本指派到与其最近的中心的类中，构成聚类结果 $C^{(t)}$

(3) 计算新的类中心。对聚类记过 $C^{(t)}$ ，计算当前个各个类中的样本的均值，作为新的类中心 $m^{(t+1)} = (m_1^{(t+1)}, \dots, m_l^{(t+1)}, \dots, m_k^{(t+1)})$

(4) 如果迭代收敛或符合停止条件，输出 $C^* = C^{(t)}$ ；否则，令 $t = t + 1$ ，返回步骤(2)

给定含有5个样本的集合：

$$X = \begin{bmatrix} 0 & 0 & 1 & 5 & 5 \\ 2 & 0 & 0 & 0 & 2 \end{bmatrix}$$

试用 k 均值聚类算法将样本聚到两个类中

(1) 选择两个样本点作为类的中心。假设选择 $m_1^{(0)} = x_1 = (0, 2)^T$ ， $m_2^{(0)} = x_2 = (0, 0)^T$

(2) 以 $m_1^{(0)}$ ， $m_2^{(0)}$ 为类 $G_1^{(0)}$ ， $G_2^{(0)}$ 的中心，计算 $x_3 = (1, 0)^T$ ， $x_4 = (5, 0)^T$ ， $x_5 = (5, 2)^T$ 与 $m_1^{(0)} = (0, 2)^T$ ， $m_2^{(0)} = (0, 0)^T$ 的欧式距离平方

(a) 对 $x_3 = (1, 0)^T$ ， $d(x_3, m_1^{(0)}) = 5$ ， $d(x_3, m_2^{(0)}) = 1$ ，将 x_3 分到类 $G_2^{(0)}$

(b) 对 $x_4 = (5, 0)^T$ ， $d(x_4, m_1^{(0)}) = 29$ ， $d(x_4, m_2^{(0)}) = 25$ ，将 x_4 分到类 $G_2^{(0)}$

(c) 对 $x_5 = (5, 2)^T$ ， $d(x_5, m_1^{(0)}) = 25$ ， $d(x_5, m_2^{(0)}) = 29$ ，将 x_5 分到类 $G_1^{(0)}$

(3) 得到新的类 $G_1^{(1)} = \{x_1, x_5\}$ ， $G_2^{(1)} = \{x_2, x_3, x_4\}$ ，计算类的中心 $m_1^{(1)}$ ， $m_2^{(1)}$ ：
 $m_1^{(1)} = (2.5, 2.0)^T$ ， $m_2^{(1)} = (2, 0)^T$

(4) 重复步骤(2)和(3)。将 x_1 分到类 $G_1^{(2)}$ ，将 x_2 分到类 $G_2^{(2)}$ ， x_3 分到类 $G_2^{(2)}$ ， x_4 分到类 $G_2^{(2)}$ ， x_5 分到类 $G_1^{(2)}$ ，得到新的类 $G_1^{(2)} = \{x_1, x_5\}$ ， $G_2^{(2)} = \{x_2, x_3, x_4\}$

由于得到的新的类没有改变，聚类停止。得到聚类结果：

$$G_1^* = \{x_1, x_5\}, G_2^* = \{x_2, x_3, x_4\}$$

K 均值聚类的算法特性

- 收敛性
 - k 均值聚类属于启发式方法，不能保证收敛到全局最优，初始中心的选择会直接影响聚类结果
- 初始类的选择
 - 选择不同的初始中心会得到不同的聚类结果
- 类别 k 的选择
 - k 均值聚类中的类别数 k 值需要预先指定，而在实际应用中最优的 k 值是不知道的

主要内容

- 人工智能和机器学习的基本概念
- 自然语言处理中常用的机器学习算法
 - 朴素贝叶斯
 - 逻辑斯谛回归
 - LDA
 - K均值聚类算法
- 常用的评价指标

评价指标

- 正确率 (Precision, 简记为 P)
 - 以信息检索为例, 正确率为返回结果中相关文档所占的比例

$$Precision = \frac{\text{返回结果中相关文档的数目}}{\text{返回结果的数目}} = P(\text{relevant}|\text{retrieved}) \quad P = tp/(tp + fp)$$

- 召回率 (Recall, 简记为 R)
 - 返回的相关文档所占所有相关文档的比例

$$Recall = \frac{\text{返回结果中相关文档的数目}}{\text{所有相关文档的数目}} = P(\text{retrieved}|\text{relevant}) \quad R = tp/(tp + fn)$$

	相关 (relevant)	不相关 (nonrelevant)
返回(retrieved)	真正例(true positive, tp)	伪正例(false positives, fp)
未返回(not retrieved)	伪反例(false negatives, fn)	真反例(true negatives, tn)

评价指标

- F 值是融合正确率和召回率的指标，是正确率和召回率的调和平均

$$F = \frac{1}{\alpha \frac{1}{P} + (1 - \alpha) \frac{1}{R}} = \frac{(\beta^2 + 1)PR}{\beta^2 P + R}$$

- 其中, $\beta^2 = \frac{1-\alpha}{\alpha}$
- 当 $\beta = 1$ 时, F 的计算公式可以简化为 $F_{\beta=1} = \frac{2PR}{P + R}$
- $\beta < 1$ 时, F 强调正确率
- $\beta > 1$ 时, F 强调召回率, 例如如果强调召回率的话, β 可以取3或者5

评价指标

- F 值是融合正确率和召回率的指标，是正确率和召回率的调和平均

$$F = \frac{1}{\alpha \frac{1}{P} + (1 - \alpha) \frac{1}{R}} = \frac{(\beta^2 + 1)PR}{\beta^2 P + R}$$

- 宏平均 F 值 分别计算每个实体类别的 F 值，然后取平均
 - 每个类是等价的权重
- 微平均 F 值 计算所有数据的 F 值
 - 每个样本是等价的

评价指标

- N 元语法的困惑度(perplexity) 是对 N 元语法模型的一种最常见内在评测的度量指标
 - 困惑度的直观解释是，给定两个概率模型，其中比较好的模型就是那个与测试数据密切适应或者能够更好地预见测试数据的细节的模型。
 - 可以通过观察模型指派给测试数据的概率来测试什么样的预见比较好，比较好的模型将会给测试数据指派比较高的概率。
 - 一个测试集上语言模型的困惑度(perplexity, PP)是该语言模型指派给测试集的概率函数，对于测试集 $W = w_1 w_2 \cdots w_N$ ，困惑度就是用单词数归一化之后的测试集的概率

$$PP(W) = P(w_1 w_2 \cdots w_N)^{-\frac{1}{N}} = \sqrt[N]{\frac{1}{P(w_1 w_2 \cdots w_N)}} = \sqrt[N]{\prod_{i=1}^N \frac{1}{P(w_i | w_1 \cdots w_{i-1})}}$$

单词序列的条件概率越高，困惑度越低。

评价指标

首先在容量为3800万单词的语料上训练一元语法、二元语法和三元语法，语料来自《Wall Street杂志(WSJ)》，词汇包含19979个单词。

然后，在150万个单词的测试集上计算每一种模型的困惑度。

	一元语法	二元语法	三元语法
困惑度	962	170	109




N元语法给我们关于单词序列的信息越多，**困惑度就越低**。

评价指标

- 纯度

- 考察聚类性能的外部指标主要有纯度 $P = (\Omega, C) = \frac{1}{N} \sum_k \max_j |w_k \cap c_j|$

其中， N 表示总的样本数； $\Omega = \{w_1, w_2, \dots, w_K\}$ 表示聚类后的簇，而 $C = \{c_1, c_2, \dots, c_J\}$ 表示正确的类别； w_k 表示聚类后第 k 个簇中的所有样本； c_j 表示聚类后第 j 个类别中真实的样本。这里的 P 取值范围为 $[0,1]$ ， P 越大表示聚类效果越好。



$$P = \frac{1}{17} (5 + 4 + 3) = 0.706$$

评价指标

- 兰德系数
 - 首先给出定义：
 - TP：表示两个同类样本点在同一个簇（布袋）中的情况数量；
 - FP：表示两个非同类样本点在同一个簇中的情况数量；
 - TN：表示两个非同类样本点分别在两个簇中的情况数量；
 - FN：表示两个同类样本点分别在两个簇中的情况数量

	同簇	非同簇
同类	TP	FN
非同类	FP	TN

评价指标

- 兰德系数

	同簇	非同簇
同类	TP	FN
非同类	FP	TN

$$RI = \frac{TP + TN}{TP + FP + FN + TN}$$


$$Precision = \frac{TP}{TP + FP}$$

$$recall = \frac{TP}{TP + FN}$$

$$F_{\beta} = (1 + \beta^2) \frac{Precision \cdot Recall}{\beta^2 \cdot Precision + Recall}$$

评价指标

- 兰德系数




	同簇	非同簇
同类	TP=20	FN=24
非同类	FP=20	TN=72


评价指标

- 兰德系数


cluster 1



cluster 2



cluster 3






$$TP = \binom{5}{2} + \binom{4}{2} + \left(\binom{3}{2} + \binom{2}{2} \right) = 20 \quad FP = \binom{1}{1} \binom{5}{1} + \binom{4}{1} \binom{2}{1} + \binom{2}{2} + \binom{3}{1} \binom{2}{1} = 20$$

$$FN = \left[\binom{5}{1} \left(\binom{1}{1} + \binom{2}{1} \right) + \binom{1}{1} \binom{2}{1} \right] + \binom{4}{1} \binom{1}{1} + \binom{3}{1} \binom{1}{1} = 24$$

$$TN = \left(\binom{5}{1} \binom{5}{1} + \binom{1}{1} \binom{2}{1} \right) + \left(\binom{4}{1} \binom{5}{1} + \binom{1}{1} \binom{2}{1} + \binom{1}{1} \binom{3}{1} \right) + \left(\binom{3}{1} \binom{5}{1} + \binom{3}{1} \binom{1}{1} + \binom{2}{1} \binom{1}{1} \right) = 72$$

评价指标

- 兰德系数



$$TP = 20 \quad FP = 20 \quad FN = 24 \quad TN = 72$$

$$RI = \frac{TP + TN}{TP + FP + FN + TN} = \frac{20 + 72}{20 + 20 + 24 + 72} \approx 0.68$$

$$Precision = \frac{20}{20 + 20} = 0.5 \quad recall = \frac{20}{20 + 24} \approx 0.46 \quad F_1 = 2 \times \frac{0.5 \times 0.46}{0.5 + 0.46} \approx 0.48$$

小结

- 人工智能和机器学习的基本概念
- 自然语言处理中常用的机器学习算法
 - 朴素贝叶斯
 - 逻辑斯谛回归
 - LDA
 - K均值聚类算法
- 常用的评价指标